Universidade de Pernambuco
Escola Politècnica de Pernambuco
Programa de Pòsgraduação em Engenharia da Compuatação

Pablo Vinicius Alves de Barros

Um Sistema Para Reconhecimento e Previsão de Gestos Dinâmicos

Dissertação de Mestrado

Recife, Julho 2013

Universidade de Pernambuco
Escola Politécnica de Pernambuco
Programa de Pósgraduação em Engenharia da Compuatação

Pablo Vinicius Alves de Barros

Um Sistema Para Reconhecimento e Previsão de Gestos Dinâmicos

Dissertação de Mestrado

Dissertacão apresentada no Programa
de Posgraduação em Engenharia da
Compuatação como parte requerida
para a obtenção do título de
Mestre em Engenharia da Computação.

Orientador: Prof. Dr. Sérgio Murillo Maciel Fernandes

Recife, Julho de 2013

Dedicatória

Gostaria de dedicar esse trabalho em primeiro lugar aos meus pais pois sempre estiveram presentes em todos os momentos da minha vida, sempre incentivando e alimentando a minha curiosidade e me fazendo ser o quem eu sou hoje. Devo tudo a eles. Agradeço também aos meus familiares por acompanharem a evolução deste trabalho e da minha vida acadêmica, mesmo à distância.

Gostaria de agradecer ao meu orientador Prof. Dr. Sérgio Murilo, bem como ao professor Msc. Bruno Fernandes, por estarem sempre acompanhando de perto, dando palpites, sugestões e as direções para que esse trabalho fosse realizado. Agradeço as orientações recebidas, tanto nesse trabalho como fora dele, pois culminaram nos vários acontecimentos que vieram a ocorrer durante a realização desse trabalho, e não foram poucos, bem como nos que irão acontecer a partir de agora.

Um agradecimento ao grupo de pesquisa RPPDI, em especial ao Prof. Byron Leite, por auxiliar em algumas orientações para esse trabalho. Agradeço efusivamente à Nestor Júnior e Juvenal Bisneto, que trabalharam lado a lado comigo para a realização desse trabalho. Todas as madrugadas, manhãs, tardes e noites escrevendo códigos, gravando gestos e torcendo para que tudo funcionasse acabaram rendendo este trabalho e todas as publicações obtidas com ele. E uma quem sabe o embrião para a SKYNET movida à quadricópteros voadores controlados pelo Kinect. Agradeço também aos membros do RPPDI, Felipe, Gearlles, Milla, Everalda entre outros, que sempre apoiaram no desenvolvimento desse trabalho, ajudando sempre que possível, principalmente nos dias do *cupcake*.

Agradeço à Universidade de Pernambuco, Escola Politécnica de Pernambuco, por toda a infra-estrutura que foi utilizada para o desenvolvimento deste trabalho, por todo o suporte e apoio nas apresentações dos artigos publicados, bem como em outros eventos acadêmicos relacionados, ou não, a este trabalho.

Agradeço ao corpo docente do curso de Pós Graduação em Engenharia da Computação - PPGE, da Universidade de Pernambuco, por todo o apoio acadêmico nas áreas afins com esse trabalho, através das aulas ministradas e conselhos dados. Agradeço também à ajuda da sempre prestativa Georgina, que me salvou em várias ocasiões durante todo o curso. Um salve aos alunos de mestrado da turma 2011.2, bem como das subsequentes, por tudo que passamos juntos nesse curso.E não foi pouca coisa. Sim, Probabilidade e Processos Estocásticos, estou falando de você.

Um agradecimento ao pessoal do *Knowledge Technology Group*, da Universidade de Hamburgo, por ter aceito a continuação deste trabalho em um PHD, a ser realizado na Alemanha, com início em outubro próximo. *Vielen Dank für die Gelegenheit.*

Um agradecimento aos amigo(a)s, irmãos(ãs) de uma vida toda, Márcio 'Winne' Alfredo, Márcio Lordelo, Francisco Júnior, Diego 'Thurran' George, Leandro Cavalcanti, Ilzy 'Yah' Souza, Marcelo 'Mars' Maurício, Jessika Barbosa e Willa Magna por ajudarem corrigindo e dando palpites em algumas sessões deste trabalho. Estejam prontos, que daqui a três anos vou precisar de vocês novamente. E aprendam alemão, pode vir a ser útil.

Epígrafe

Daqui para frente, estaremos deixando o terreno firme dos fatos para viajar juntos pelos turvos alagados da memória e nos embrenhar pelo matagal das suposições mais absurdas. (A. Dumbledore)

Recife, Junho 2013

Resumo

A área de reconhecimento de gestos vem sendo estudada à algumas décadas, e nesta última vários avanços foram atingidos, devido à evolução da tecnologia e da capacidade de processamento dos computadores. Alguns desses avanços já permitem que a comunicação entre homens e máquina se dê através de gestos simples, utilizando um dedo ou uma mão capturados por uma câmera de vídeo comum, ou até mesmo a captura de gestos realizados pelo corpo como um todo, capturados por dispositivos específicos para isso.

De forma a facilitar o uso de gestos como interação, a utilização da visão computacional vem sendo explorada com afinco pelos pesquisadores. O uso da visão computacional faz com que gestos possam ser capturados em ambientes reais, sem a necessidade de utilizar dispositivos específicos para a captura ou rastreamento dos gestos. Através da captura por câmeras, um método não invasivo, pode-se utilizar esses sistemas em ambientes naturais, sem a necessidade de se investir alto ou de treinamento prévio pelo usuário.

Um dos problemas quando utiliza-se a visão computacional no reconhecimento de gestos, é a escolha de quais características se capturar, ou mesmo o tamanho desse vetor de características capturado. Esse problema acaba gerando alguns empecilhos para as técnicas utilizadas na classificação dos gestos, diminuindo a eficácia e eficiência das técnicas.

Esse trabalho de dissertação propõe um sistema para o reconhecimento e previsão de gestos dinâmicos realizados pela mão de um usuário. Esse sistema utiliza uma técnica, também proposta nesse trabalho, de extração de características da mão que seleciona somente os pontos mais eficientes e eficazes para descrição no vetor de características.

A técnica proposta é avaliada dentro do sistema proposto e comparada com outras técnicas, o *[Local Contour Sequence* (LCS) e o *Speed Up Robust Features* (SURF). Quatro técnicas de classificação são implementadas para os testes, *Dynamic Time Warping* (DTW), Modelo Oculto de Markov (HMM) e Rede Neural de Elman (Elman RNN). São realizados três experimentos, um para a classificação de gestos estáticos, um para classificação de gestos dinâmicos e um para a classificação de gestos dinâmicos incompletos, simulando a previsão de gestos.

Os resultados são apresentados e discutidos, detalhando as vantagens e desvantagens de cada técnica utilizada.

Abstract

Several studies in gesture recognition have being developed in the last decades, reaching enormous advances through the technology evolution and the increase in the computer processing. Some of these advances, allow the communication between men and machine can be done by simple gesture captured by a video camera, executed by a hand or a finger. Even a full body gesture recognition can be done, using some specific devices.

The utilization of computer vision have been adopted by researchers with intuit of facilitate gesture interaction. Computer vision allow a gesture to be recognized by a single video camera in natural environments, without the need of a specific device for capture or tracking. This non-invasive method permits the recognition without a hight investment in hardware or a previous training by the user.

One of the problems using computer vision in gesture recognition, is the choose of which characteristics capture, or even, the size of these characteristics vector. This problem ends up generating some other problems for the classification techniques, such as the lost of efficiency and effectiveness in the recognition task.

This dissertation work proposes a dynamic gesture recognition and prediction system. This system uses a novel technique, proposed in this work also, for feature extraction applied in the hand of a user, that choses the most effective points in the hand contour, and improves the recognition rate.

The proposed technique is evaluated with the proposed system, and their results are compared with other feature extraction techniques, Local Contour Sequence - LCS and Speed Up Robust Features - SUEF. Four classification techniques are implemented in the system: Dynamic Time Warping - DTW, Hidden Markov Model - HMM and Elman Recurrent Neural Network (Elman RNN). Three experiments are realized, one for classification of static gestures, the second for classification of dynamic gestures and the last one for classification of incomplete gestures, simulating a prediction.

The results are showed and discussed, detailing the good points and bad points of each technique.

Sumário

Lista de Figuras

Lista de Tabelas

List of Algorithms

Capítulo 1

Introdução

Sistemas de reconhecimento de gestos proporcionam uma forma natural e amigável de interação com sistemas computacionais, que se tornam mais naturais para seres humanos. A área de reconhecimento de gestos busca identificar padrões de movimentos em seres humanos, aprende-los e generaliza-los de forma que seja possível reconhece-los ao serem executados por qualquer pessoa. Existem várias aplicações nesse campo de estudo como aplicações em jogos eletrônicos [LH10] [RA11], interação entre homens e robôs [BDH13] [Lee06], interação com aparelhos televisores [JJS+12a] e reconhecimento de linguagem de sinais [CH11] [ZCZ+08] [SA07].

Hoje em dia utilizando nada mais do que uma câmera de vídeo em um telefone celular, *tablet* ou *notebook* é possível capturar gestos realizados por seres humanos. E já que a maioria das pessoas têm a sua disposição pelo menos um desses aparelhos, a utilização de uma interação baseada em gestos se torna ainda mais natural e necessária. A evolução dos computadores também auxilia nesse processo, já que mesmo aparelhos celulares dispõe de um poder computacional suficiente para executar essa tarefa, podendo ser aplicadas técnicas baseadas em visão computacional nos próprios aparelhos.

Sistemas para reconhecimento de gestos dinâmicos podem ser separados em três categorias [IK12]: Sistemas que utilizam luvas ou sensores externos ligados ao corpo do usuário para captar o gesto executado [HMWA11] [XGDT10] [JLK11] [KTK09] [Han10]. Essa abordagem tende à captação mais precisa dos gestos executados porém se torna invasiva ao usuário já que ele utiliza um hardware muitas vezes incômodo para a captura. A aplicação de luvas de captura se da em um ambiente controlado, onde as luvas são conectadas a um computador, tornando complicada sua utilização em um ambiente externo como por exemplo uma aplicação em mundo real.

A segunda abordagem trata da identificação do gesto através do movimento, rastreando o gesto desenhado pelo usuário [SCO11] [JJS+12b] [CR11] [COB+04]. Essa captura pode ser feita com um mouse ou mesmo através de uma câmera, fazendo o rastreio do usuário como um todo ou de algum membro em específico. Essa abordagem utiliza um conceito simplificado de gesto o que torna mais fácil o reconhecimento, porém os gestos que podem ser expressados por essa abordagem são menos significativos e menos precisos do que os representados pelas outras

abordagens.

A última categoria utiliza câmeras para capturar o gesto e identificá-lo através de vários fatores: sua movimentação, posicionamento, velocidade, cor, observações biométricas entre outros [ZZ08] [SCH+05] [BNT09] [LBM01] [KK10]. Essa abordagem é a que contempla um conceito de gesto mais amplo e é menos incômodo ao usuário, já que sua captura se dá através de uma câmera de vídeo, seja ela de um *smartphone*, *notebook* ou mesmo uma câmera de segurança. Essa abordagem utiliza técnicas de visão computacional para identificar o gesto que está sendo realizado e classifica-lo através das imagens obtidas na câmera de vídeo.

Uma característica desejada pelos sistemas de reconhecimento de gestos, é a capacidade de reconhecimento em tempo real, aplicadas em situações reais. Alguns trabalhos apresentam soluções para esses problemas, mas como debatido por [MUK+06], um sistema para reconhecimento de gestos de atuação em tempo real precisa ser capaz de prever o gesto antes mesmo que ele aconteça, de forma que o sistema obtenha respostas em tempo hábil, facilitando o processamento dos dados. Essa capacidade é denominada previsão de gestos, onde um gesto parcial é reconhecido com sucesso.

A predição melhora o reconhecimento, tentando identificar um padrão antes que ele seja executado por completo. Técnicas de predição vem sendo utilizadas com sucesso para melhorar o reconhecimento de voz [ST07] [HJAJG09] [VH99] [SGS11] [HN07]. Poucos trabalhos utilizam o conceito de previsão de gestos para o reconhecimento de gestos dinâmicos, como descrito por [MUK+06].

1.1 Motivação e Objetivos

A utilização de sistemas para reconhecimento de gestos como forma de interação natural já vem sendo explorada, como citado anteriormente, mais alguns aspectos ainda precisam ser melhorados. A diminuição do tempo de processamento para o reconhecimento pode ser melhorado, tanto com a captura de um vetor de características menor, como com a utilização de previsão de gestos, de forma que um gesto incompleto, ainda sendo realizado, possa ser reconhecido. Outro problema citado é a falta de uma base de gestos dinâmicos que possa ser utilizada para o teste de algoritmos de extração de características. As bases de dados existentes tendem a ser muito complexas, e acabam tirando o foco da sua utilização para teste de algoritmos de extração [HK12].

Várias técnicas são aplicadas na extração de características para o reconhecimento de gestos, porém muitas delas são afetadas por um problema delimitado maldição da dimensionalidade, como exibido no trabalho publicado por [BAESS11]. A maldição da dimensionalidade diz que uma aproximação numérica de uma função irá ter um custo computacional maior de acordo com o crescimento de variáveis utilizadas por ela [KE11]. Para resolver esse problema, essa dissertação propõe um método de diminuição do vetor de características para reconhecimento de gestos dinâmicos baseado na seleção das características mais eficientes e eficazes para o reconhecimento.

Um sistema para o reconhecimento de gestos dinâmicos é proposto nesse trabalho de dissertação. De forma a resolver alguns dos problemas citados acima, uma técnica de extração de características de gestos dinâmicos realizados com a mão é proposta. Essa técnica utiliza como entrada o contorno de uma mão, extraído de uma imagem. De forma a obter um resultado otimizado, essa técnica é aplicada em outras duas técnicas de extração, o *Local Contour Sequence* (LCS) e o *Speed Up Robust Feature* (SURF). O LCS e o SURF conseguem extrair o contorno da mão através de métodos diferentes. O LCS utiliza uma série de técnicas de processamento de imagens para extrair o contorno da mão e aplica um cálculo de distância entre os pontos do contorno, formando o vetor de características que descreve a mão. O SURF utiliza de uma série de operações matemáticas para extrair os pontos de interesse em uma imagem, e a partir dai extrair um vetor de característica que descreve esses pontos.

A técnica proposta nesse trabalho, denominada Abordagem Convexa, utiliza a mesma ideia de extração de um vetor de características a partir dos pontos do contorno da mão presentes no LCS. Ao invés de extrair as características utilizando o contorno completo extraído pelo LCS, a Abordagem Convexa procura minimizar o contorno, selecionando os pontos que mais eficientemente conseguem representar a mão. A aplicação da Abordagem Convexa no LCS é denominada CLCS. A Abordagem Convexa também é aplicada nos pontos de interesse extraídos pelo SURF, gerando o CSURF.

Essas duas novas técnicas, o CLCS e o CSURF, são utilizadas dentro do sistema de reconhecimento de gestos dinâmicos proposto por esse trabalho.Os resultados obtidos são comparados com resultados obtidos utilizando o LCS e o SURF.

De forma a testar o sistema proposto e a Abordagem Convexa aplicada ao LCS e o SURF, vários testes são executados. Além do teste para o reconhecimento de gestos dinâmicos, citado acima, o reconhecimento de gestos estáticos e a previsão de gestos também são testados.O sistema implementa três técnicas de classificação diferentes, de forma que os resultados possam ser comparados com a combinação de todas as técnicas. As três técnicas implementadas são: Modelos Ocultos de Markov (HMM), Rede Neural de Elman (Elman RNN) e *Dynamic Time Warping* (DTW).

Esse trabalho também apresenta uma nova base de gestos dinâmicos contendo sete gestos realizados pela mão de um usuário. Essa base possui a característica de facilitar o teste dos algoritmos de extração, visto que ela é desenvolvida com um fundo estático e contém gestos com várias posturas de mão diferentes.

1.1.1 Objetivos Específicos

- Propor um sistema para o reconhecimento de gestos dinâmicos, gestos estáticos e previsão de gestos.

- Propor uma técnica de extração de características para gestos baseados na mão de um usuário, que pode ser utilizada em conjunto com o LCS e o SURF.

- Avaliar a técnica de extração de características, comparando os resultados obtidos com resultados obtidos pelo LCS e o SURF.
- Avaliar o sistema de reconhecimento de gestos com a utilização das quatro técnicas de extração de características citadas acima, LCS, SURF, CLCS e CSURF. A combinação das quatro técnicas de extração de características com cada uma das técnicas de classificação, DTW, HMM e Elman RNN, são testadas.
- Propor uma base de gestos dinâmicos de mão.

1.2 Estrutura deste Documento

Para um melhor entendimento desta dissertação, é indicada uma leitura sequencial. Essa dissertação está estruturada da seguinte forma:

- Capítulo 1 Apresenta a motivação e objetivos deste trabalho;
- Capítulo 2 Descreve o estado da arte em reconhecimento de gestos e trabalhos relacionados a este tema;
- Capítulo 3 Descreve o novo método para extração de características e sistema para reconhecimento de gestos propostos.;
- Capítulo 4 Apresenta a base de gestos desenvolvida, exibe a metodologia aplicada nos testes do sistema proposto e os resultados obtidos;
- Capítulo 5 Descreve as contribuições do trabalho proposto, a conclusao e trabalhos futuros;

Capítulo 2

Fundamentos em Reconhecimento de Gestos

A maioria dos sistemas que utilizam visão computacional para o reconhecimento de gestos dinâmicos [HK12] são divididos em dois módulos: extração ou aquisição de características e aprendizagem ou classificação do gestos. A tarefa de extração de característica se mostra a mais desafiadora pois envolve vários elementos com características dinâmicas e complexas como iluminação, *background* complexos e imagens incompletas. Para resolver a maior parte desses problemas, técnicas de processamento de imagem são aplicados e limitações na captura ou no reconhecimento são impostas. Cada problema requer uma técnica ou conjunto de técnicas a serem aplicados e a escolha dessas técnicas deve ser feita com cuidado levando em consideração o tipo de gesto, a quantidade de usuários e o ambiente de captura dos gestos, por exemplo. Uma das limitações mais comuns é a observação de somente um membro do corpo humano, e como a mão é o membro que consegue caracterizar uma quantidade maior de gestos, ela é comumente escolhida [PSH97].

2.1 Gestos e Sinais

Um gesto pode ser executado por um ou mais seres humanos, através da movimentação de braços, mãos, dedos, cabeça, pernas ou mesmo o corpo inteiro. Pode expressar informações, sentimentos, representar conceitos ou ser o meio de comunicação entre várias pessoas ou até mesmo pessoas e máquinas. Gestos também podem ter conceitos diferentes dependendo do contexto onde se encontram, e a união de vários gestos pode ter significados diferentes dos encontrados quando separados. Gestos podem ser classificados de acordo com sua execução em relação ao tempo [Gav99]:

- Estáticos: Uma certa posição específica de mãos, braços, pernas ou cabeça representa o gesto. Este cenário não necessita nenhuma alteração do gesto para que ele seja executado. O usuário precisa permanecer na posição por um tempo determinado de forma que o gesto possa ser interpretado.

- Dinâmico: O gesto é o resultado de uma sequência de gestos estáticos e os movimentos necessários para realiza-los. Um gesto dinâmico leva em consideração, além da posição específica dos membros, a sua movimentação. Este cenário é mais complexo pois cada pessoa pode realizar a movimentação do gesto de formas e em velocidades diferentes.

Outra classificação de gestos pode ser em relação aos seus usuários [AC99]:

- Monousuário: Gestos monousuários são executados por um ser humano. Nesta modalidade, um gesto é realizado por um só ser humano utilizando o seu próprio corpo. É a modalidade que está presente na maioria das aplicações que utilizam gestos, como nas línguas de sinais, e interação homem máquina.

- Multiusuário: Nessa modalidade a conjunção de movimentos realizados por dois ou mais seres humanos, ou mesmo de seres humanos e objetos inanimados representam um gesto. Um gesto multiusuário é mais complexo e é totalmente dependente de contexto, já que sua utilização está mais voltada para jogos eletrônicos ou interpretação de ações em contextos informais, por exemplo um filho perguntando à sua mãe onde guardar um pacote segurando-o na mão e apontando para o armário.

Uma das aplicações mais complexas envolvendo gestos são as Línguas de Sinais. Cada Língua de Sinais é considerada um idioma à parte, com suas próprias regras gramaticais, sintáticas e semânticas. As línguas de sinais espalhadas pelo globo se baseiam em gestos dinâmicos e monousuários. Cada sinal nas Línguas de Sinais podem ser representados por um ou mais gestos e possuem um ou vários significados, dependendo do contexto.

No Brasil a Língua de Sinais utilizada é denominada Língua Brasileira de Sinais – LIBRAS. Em LIBRAS um sinal é composto por cinco características [LNV+12]: Posição das mãos e dos braços, Movimento das mãos e braços, Orientação da movimentação, Posição das mãos em relação ao corpo e expressão facial. Cada sinal de libra é composto por variações dessas características, podendo dois ou mais sinais conterem as mesmas posições, movimentações ou mesmo expressões faciais, executadas em momentos diferentes. Sinais iguais podem ter significados diferentes dependendo do contexto, ou apresentarem uma variação mínima em uma das cinco configurações.

2.2 Processamento de Imagens Digitais

Um dos problemas mais comuns no reconhecimento de gestos baseados em visão computacional é a extração de características das imagens para um reconhecimento correto. Várias abordagens já foram aplicadas para isso, como no trabalho de [RMM+09] que reconhece um gesto através da posição dos dedos. Cada dedo aberto é reconhecido a partir do contorno da mão. Nesse trabalho os pontos

concentrados no centro da mão são eliminados e os que restam são marcados como dedos abertos. Para cada dedo aberto, sua ponta é encontrada através da análise dos pontos mais distantes naquele segmento de pontos. Após encontrar as pontas dos dedos abertos em uma mão, eles são comparados com uma base de dados contendo os gestos conhecidos pelo sistema. A distância entre o gesto a ser classificado e os gestos já conhecidos é calculada utilizando uma soma da distância de cada ponto. Esse trabalho é aplicado ao reconhecimento de gestos estáticos provenientes da Língua Americana de Sinais obtendo uma taxa de 95% dos gestos classificados corretamente.

No trabalho de [FWCL07] o gesto é reconhecido através da detecção da palma da mão e da orientação dos dedos em relação à palma. Ele utiliza o algoritmo de reconhecimento de Blobs desenvolvido por [Lin98] para o reconhecimento da palma da mão e dos dedos em uma imagem com *background* complexo. Utilizando uma base de dados com seis gestos dinâmicos uma média de 90% dos gestos são reconhecidos corretamente.

[SP09] utiliza-se da análise da topografia de Redes Neurais Alto Organizadas para o reconhecimento de gestos. Uma *Self-Growind and Self-Organized Neural Gas* (SGONG) é utilizada. O contorno de uma mão é colocado na rede e a topografia que a rede atinge ao final de sua execução é utilizada como extração de característica para aquele gesto. O sistema foi testado no reconhecimento de 31 gestos estáticos e obteve uma taxa de 31% de gestos reconhecidos corretamente.

Os trabalhos citados anteriormente utilizam técnicas de processamento de imagens para a extração de características da mão em uma imagem. Para a maioria das técnicas de extração de características, bem como nas técnicas abordadas por esse trabalho, encontrar o contorno da mão é uma tarefa primordial. A sessão a seguir exibe um método para extração do contorno de uma mão utilizado nos trabalhos citados anteriormente.

2.2.1 Extração de contorno

O processo de segmentação de uma imagem ajuda a separar o objeto a ser utilizado reconhecido, separando a imagem em dois elementos: objeto e fundo. Para o reconhecimento de gestos realizados por uma mão, a mão é considerada o objeto a ser reconhecido e tudo que não for mão tem que ser eliminado da imagem, sendo classificado como fundo.

Uma das técnicas mais utilizadas para a segmentação de imagens é o *Otsu Treshold* [Ots79]. Essa técnica consegue segmentar uma imagem, originalmente em tons de cinza, transformando-a em uma imagem binarizada. Uma imagem binarizada é aquela cujo seus *pixels* possuem apenas dois valores: 0 ou 1, e é muito utilizada para representação de imagens pois possui um tamanho ínfimo comparado a uma imagem comum, facilitando qualquer tipo de operação a ser realizada com ela.

O propósito do *Otsu* é encontrar um *treshold* K, que separe uma imagem em níveis de cinza nas duas classes: fundo e objeto, neste caso, a mão. A Figura 2.1 exibe uma ilustração do uso do *treshold* K no processo de binarização da imagem.

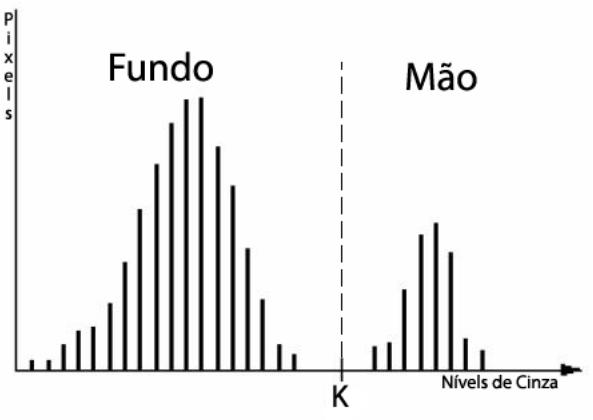

Figura 2.1: Processo de binarização de uma imagem em tons de cinza utilizando K como *treshold*.

O *Otsu* inicia-se calculando a quantidade de *pixels* η_i para cada tom de cinza i e denomina-se η como o total de *pixels* na imagem, ou seja, $\eta = \eta_1+\eta_2+\eta_3+\eta_4...+\eta_i$. A distribuição de probabilidade para o nível i é dado por ρ_i:

$$\rho_i = \frac{\eta_i}{\eta} \tag{2.1}$$

Então calcula-se a probabilidade $\omega 0(K)$, que define a probabilidade do intervalo de níveis de cinza [0,K] pertencer a classe fundo, e $\omega 1(K)$, que define a probabilidade do intervalo [$K+1$,L] pertencer a classe mão, onde L é o último nível de cinza encontrado na imagem. Essas probabilidades são definidas por:

$$\omega 0(K) = \sum_{i=1}^{K} \rho_i \tag{2.2}$$

$$\omega 1(K) = \sum_{i=K+1}^{L} \rho_i = 1 - \omega 0 \tag{2.3}$$

O próximo passo é o cálculo da média das probabilidades de cada classe, μ_0 para a classe fundo e μ_1 para a classe mão, que serão utilizadas para o cálculo da variância de cada classe. A média das probabilidades é dada por:

$$\mu_0(K) = \frac{\sum_{i=1}^{K} \rho_i \bar{i}}{\omega_0(K)} \tag{2.4}$$

$$\mu_1(K) = \frac{\sum_{i=K+1}^{L} \rho_i \bar{i}}{\omega_1(K)} \tag{2.5}$$

Nas equações acima, $\bar{i}$ representa a mediana do intervalo [1,K] para a classe fundo e do intervalo [$k+1$,L] para a classe mão. O próximo passo é o cálculo da variância de cada classe, denominada σ_0^2(K) para a classe fundo e $\sigma_1^2(K)$ para a classe mão:

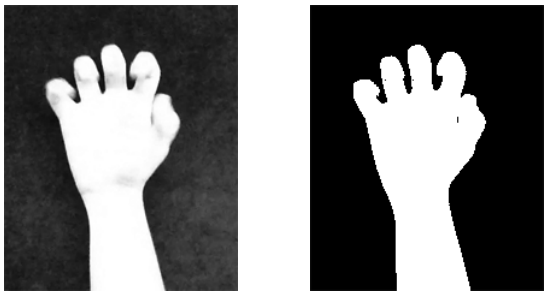

(a) Imagem Original

(b) Imagem Binarizada

Figura 2.2: Resultado da aplicação do *Otsu Treshold* em uma imagem de postura de mão. (a) exibe a imagem original e (b) a saída do *Otsu Treshold*.

$$\sigma_0^2(K) = \frac{\sum_{i=1}^{K}(\rho_i - \mu_0)^2}{\omega_0(K)} \tag{2.6}$$

$$\sigma_1^2(K) = \frac{\sum_{i=K+1}^{L}(\rho_i - \mu_1)^2}{\omega_1(K)} \tag{2.7}$$

Por fim a variância entre as duas classes, definida por σ_w^2(K), é calculada:

$$\sigma_w^2(K) = \omega_0(K)\sigma_0^2(K) + \omega_1(K)\sigma_1^2(K) \tag{2.8}$$

A variância entre as duas classes é calculada para todos os valores de K, ou seja, para todos os níveis de cinza encontrados na imagem. O valor de K que obter o maior $\sigma_w^2(K)$ é então escolhido para ser o *treshold* da imagem, e todos os *pixels* pertencentes ao intervalo $[0,K]$ são marcados para ser removidos da imagem, recebendo um valor 0. Já todos os *pixels* no intervalo $[K+1,L]$ são marcados com o valor 1. A Figura 2.2 exibe o resultado de binarização de imagem utilizando o *Otsu*.

Após o processo de binarização, um segundo procedimento é executado, utilizando a imagem binarizada como entrada. Esse processo tem como objetivo eliminar todos os *pixels* que não são utilizados para a determinação da postura da mão. Em outras palavras, esse processo encontra o contorno da mão, reduzindo a quantidade de informação a ser processada pelos algoritmos de extração, otimizando todo o processo de reconhecimento.

Um dos processos mais simples e eficazes para encontrar bordas em uma imagem binária é a análise de diferença de intensidades dos *pixels*. Essa análise permite eliminar todos os *pixels* que não possuem vizinhos com variações 1-0, deixando somente os *pixels* que representam a borda da mão. Inicia-se varrendo a imagem binária à procura do primeiro pixel com valor 1. Ao encontra-lo, verifica-se se ele possui algum dos 8 vizinhos com valor 0, caso positivo marca-se esse pixel como borda. Caso negativo marca-se esse pixel como não-borda. Ao final excluem-se todos os *pixels* marcados como não borda. A Figura 2.3 exibe o resultado desse processo, quando aplicado na imagem da Figura 2.2(b).

Figura 2.3: Processo de segmentação completa, encontrando o contorno da mão.

2.2.2 Algoritmo da extração do contorno

histograma é encontrado encontrando O algoritmo do processo de segmentação da mão em uma imagem consiste na junção dos dois métodos citados anteriormente: a binarização da imagem com o *Otsu* e a delimitação da borda da imagem binária. O Algoritmo 1 exibe o pseudocódigo final do processo de segmentação da mão. Primeiro encontra-se o histograma da imagem em tons de cinza e calcula-se a probabilidade de cada tom de cinza presente no histograma, linhas 1 e 2. O *treshold* a ser aplicado no histograma é encontrado maximizando a variância entre cada um dos tons de cinza, como descrito no *Otsu Treshold*, exemplificado entre as linhas 3 e 10.

A imagem é binarizada utilizando o melhor *treshold* encontrado pelo *Otsu*, como exibido nas linhas 12 a 20. Já com a imagem binarizada, começa-se o processo de encontrar as bordas através da busca por *pixels* com variação 1-0, ou seja, pela busca de *pixels* que possuem valor 1 e algum dos vizinhos com valor 0, como demonstrado nas linhas 22 a 28.

Após todos os *pixels* serem marcados como borda, os que não possuem essa marcação são eliminados da imagem, como exibido nas linhas 30 a 38.

2.3 Extração de características

O processo de extração de características tem como função primária representar a imagem em um espaço de medidas que possa ser utilizado por um classificador. No problema de reconhecimento de gestos feitos pelas mãos de um usuário, as técnicas de extração devem ser capazes de conseguir identificar e descrever a posição e postura da mão, independente de usuário, escala e rotação.

Duas técnicas utilizadas nesse trabalho são o *Local Contour Sequence* (LCS), descrita por [GM01] e o *Speed Up Robust Features Extraction* (SURF) [BETVG08]. Essas técnicas foram escolhidas por serem técnicas ressentes e que vem sendo utilizadas na área de reconhecimento de gestos dinâmicos e estáticos. Elas apresentam bons resultados e devido à sua natureza de funcionamento, podem ser aplicadas ao reconhecimento de gestos realizados com mãos, como demonstrado no trabalho de [Mee11], que descreve um sistema de reconhecimento de gestos estáticos através dos pontos extraídos do contorno da mão. Ele utiliza uma técnica denominada

Algorithm 1: Algoritmo para segmentação de uma mão

```
1  Histograma = Histograma(Imagem);
2  Computar a probabilidade ρ_i para cada nível de cinza de Histograma;
3  VarianciaMaxima = -1;
4  MaximoTreshold = 0;
5  for Nivel de cinza K em Histograma do
6  |  variancia = σ²_w(K);
7  |  if variancia>VarianciaMaxima then
8  |  |  VarianciaMaxima = variancia;
9  |  |  MaximoTreshold = K;
10 |  end
11 end
12 for y = 0 ; y<ImagemOriginal.Altura; y++ do
13 |  for x = 0 ; x<ImagemOriginal.Largura; x++ do
14 |  |  if Imagem.pixel(x,y) está no intervalo
   |  |  Histograma[0,MaximoTreshold] then
15 |  |  |  Imagem.pixel(x,y) = 0;
16 |  |  end
17 |  |  else
18 |  |  |  Imagem.pixel(x,y) = 1;
19 |  |  end
20 |  end
21 end
22 List<Pixel> Bordas;
23 for y = 0 ; y<Imagem.Altura; y++ do
24 |  for x = 0 ; x<Imagem.Largura; x++ do
25 |  |  if Imagem.pixel(x,y) for 1 e possuir algum vizinho que seja 0 then
26 |  |  |  Bordas.add(Imagem.pixel(x,y));
27 |  |  end
28 |  end
29 end
30 for y = 0 ; y<Imagem.Altura; y++ do
31 |  for x = 0 ; x<Imagem.Altura; y++ do
32 |  |  if Bordas contém Imagem.pixel(x,y) then
33 |  |  |  Imagem.pixel(x,y) = 1;
34 |  |  end
35 |  |  else
36 |  |  |  Imagem.pixel(x,y) = 0;
37 |  |  end
38 |  end
39 end
40 return Imagem.
```

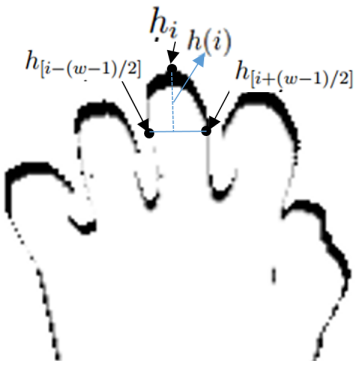

Figura 2.4: Vetor de características que descreve a Figura 2.3 obtido através da aplicação do LCS.

Local Contour Sequence (LCS), que extrai distâncias do contorno da mão, para gerar um vetor de características que representa o gesto completo, independente de qual posição a mão possa estar. Esse vetor de características é classificado por uma *Support Vector Machinne*(SVM), e para um total de 7 gestos um resultado de 90% de gestos reconhecidos corretamente foi obtido.Já no trabalho de Jiang2011 et al. [JSFJ11] é descrito a utilização dos pontos de interesse extraídos pelo SURF para o reconhecimento de gestos dinâmicos extraidos de um vídeo. [YY12] utiliza os pontos extraidos pelo SURF para reconhecer posturas de mão estáticas.

As seções a seguir explicam cada uma dessas técnicas.

2.3.1 Local Contour Sequence - LCS

O LCS é uma técnica de descrição de gestos baseada no contorno de uma mão, ele extrai um vetor de números que representa a posição que a mão está assumindo naquela imagem. O algoritmo recebe como entrada a imagem binarizada contendo o contorno de uma mão. A partir dai, encontra-se o primeiro *pixel* que faz parte do contorno, varrendo-se a imagem de cima para baixo e da esquerda para a direita. Utilizando esse pixel como referência, todos os outros *pixels* da imagem são ordenados em ordem horária.

Para ordenar os *pixels* em sentido horário a partir do primeiro *pixel*, um algoritmo de ordenação baseado em vizinhança é utilizado. Dado que o primeiro *pixel* encontrado é representado pelas coordenadas (x,y) e marcado como p_0, verifica-se se os seus vizinhos norte$(x,y+1)$, nordeste$(x+1,y+1)$, leste$(x+1,y)$, sudeste$(x+1,y-1)$,sul$(x,y-1)$, sudoeste$(x-1,y-1)$, oeste$(x-1,y)$ ou noroeste$(x-1,y+1)$ são 1. A verificação é feita nessa ordem, e o primeiro a ser encontrado é marcado como p_1 e o algoritmo é interrompido. Utilizando p_1 como referência, a verificação de vizinhança é feita novamente, da mesma maneira, seguindo a mesma ordem, e encontra-se p_2. Esse algoritmo é repetido até que percorra-se todos os pontos do contorno, nunca adicionando o mesmo ponto duas vezes.

Após obter todos os *pixels* ordenados, tem-se h_i como o pixel na posição i, ou seja $h_i = (x_i,y_i)$, de um total de N *pixels*. O LCS retorna um vetor de distâncias

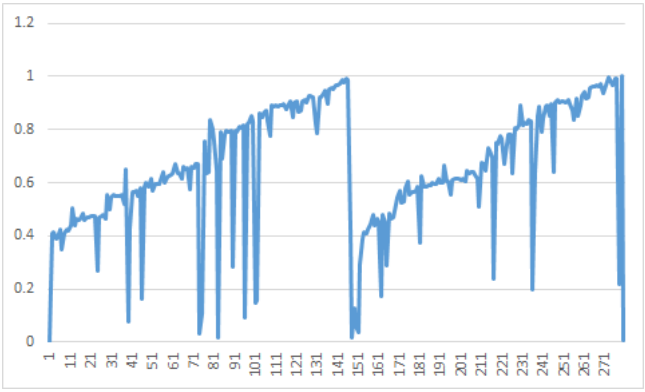

Figura 2.5: Vetor de características que descreve a Figura 2.3 obtido através da aplicação do LCS.

que representa a postura da mão. Cada distância é calculada entre o pixel h_i e uma reta formada por $h_{[i-(w-1)/2]}$ e $h_{[i+(w-1)/2]}$, onde w é um parâmetro a ser passado para o algoritmo. A Figura 2.4 exibe a ilustração do cálculo da distância para um ponto $h(i)$. O valor de cada distância, $h(i)$, pode ser calculado como:

$$h(i) = \left| \frac{\mu_i}{\upsilon_i} \right| \tag{2.9}$$

Onde μ_i e υ_i são definidos por:

$$\begin{aligned} \mu_i = x_i \left[y_{i-(w-1/2} - y_{i+(w-1/2)} \right] \\ + y_i \left[x_{i+(w-1/2} - x_{i-(w-1/2)} \right] \\ + \left[y_{i+(w-1/2} \right] \left[x_{i+(w-1/2} \right] \\ - \left[y_{i-(w-1/2} \right] \left[x_{i-(w-1/2} \right] \end{aligned} \tag{2.10}$$

$$\upsilon_i = \left[\left(y_{i-(w-1/2)} - y_{i+(w-1/2)} \right)^2 + \left(x_{i-(w-1/2)} - x_{i+(w-1/2)} \right)^2 \right]^{1/2} \tag{2.11}$$

Para todos os pontos presentes no contorno, i=1,2,3,4,5...N, o $h(i)$ é calculado e anexado no vetor de características. Como vários gestos podem ser executados em distâncias diferentes da câmera, uma normalização da amplitude dos valores extraídos se faz necessária, eliminando o fator escala. Para tanto, divide-se cada valor do vetor de características pelo desvio padrão do mesmo. A Figura 2.5 exibe o LCS da postura de mão presente na Figura 2.3, onde fora obtidos 271 pontos normalizados.

O LCS possui algumas características que auxiliam na representação dos gestos de mão. Como citado anteriormente, através de uma normalização de amplitude, o LCS se torna invariante a escala, ou seja, o gesto pode ser realizado a distâncias diferentes da câmera, obtendo-se uma descrição parecida. O algoritmo também é invariante a translação, pois o ponto inicial obtido na ordenação pode variar

dependendo da posição da mão, mas as distâncias serão as mesmas. A escolha da janela w pode afetar diretamente na construção do vetor de características. Um valor muito alto de w, cria uma amplitude maior para as distâncias, o que aumenta as chances de captação de ruído no contorno. Já a diminuição da janela w pode gerar muitas características, aumentando a quantidade de distâncias extraídas.

Durante o desenvolvimento deste trabalho, um problema observado no LCS é a quantidade de pontos obtidos por cada mão, que pode ser elevado. Esse problema pode resultar no aumento do tempo e poder computacional requeridos para a classificação do gesto, além de diminuir a taxa de reconhecimento.

2.3.2 Algoritmo LCS

O algoritmo do LCS, Algoritmo 2, é simples e de rápida execução, já que não realiza nenhuma computação complexa. o Algiritmo 2 exibe o pseudocódigo do LCS. O primeiro passo é a obtenção do primeiro *pixel* do contorno, que pode ser observada nas linhas de 1 a 9. Após isso, o pontos presentes no contorno são ordenados em sentido horário, como exibido na linha 10. Já com os pontos ordenados o cálculo do LCS é realizado, o valor da janela w é escolhida, e a distância para cada ponto é calculada e armazenada em um vetor, como exibido entre as linhas 11 e 15. Ao fim, esse vetor é normalizado, dividindo-se cada elemento do vetor pelo seu desvio padrão, como exibido na linha 16.

Algorithm 2: Algoritmo para extração de características da imagem utilizando LCS

```
1  Pixel p0;
2  for y = 0 ; y<Imagem.Altura; y++ do
3  |   for x = 0 ; x<Imagem.Largura; x++ do
4  |   |   if Imagem.pixel(x,y) == 1 then
5  |   |   |   p0 = Imagem.pixel(x,y);
6  |   |   |   break;
7  |   |   end
8  |   end
9  end
10 List<Pixel> PontosOrdenados = OrdenacaoHoraria(p0,Imagem);
11 Double LCS;
12 Escolhe-se o valor de w; for Pixel p em PontosOrdenados do
13 |   distancia = h(i);
14 |   LCS.add(distancia);
15 end
16 LCS = NormalizaLCS(LCS);
17 return LCS.
```

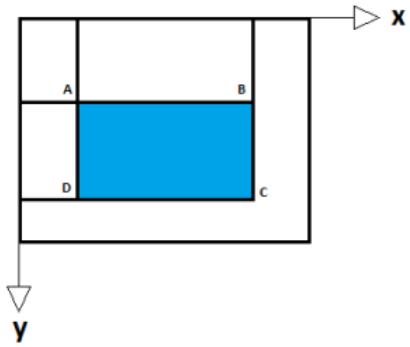

Figura 2.6: Cálculo para soma de intensidades de um data região retangular,delimitada pelos *pixels* A, B, C e D pode ser calculado executando-se a operação: $(A + C) - (B + D)$

2.3.3 Speed Up Robust Features Extraction - SURF

O SURF é um algoritmo para descrição de imagens que identifica pontos de interesse e extrai descritores desses pontos, que podem ser utilizados para classificar objetos. Nesse trabalho o SURF é utilizado para classificar gestos realizados com uma mão.

Para encontrar os pontos de interesse em uma imagem, isto é, os pontos dos quais serão obtidos os descritores, o SURF utiliza uma abordagem baseada em uma aproximação da matriz Hessiana. Através do uso de imagens integrais, o SURF consegue diminuir o custo computacional do algoritmo, resultando em uma execução rápida de todo o processo de extração dos pontos de interesse.

Uma imagem integral, utilizada na área de visão computacional pela primeira vez no trabalho de [VJ01], representa a soma dos *pixels* de uma imagem I com seus vizinhos acima e a esquerda. A equação abaixo ajuda a definir a imagem integral $I_{\sum}(X)$:

$$I_{\sum}(x, y) = \sum I(x - 1, y - 1) \tag{2.12}$$

Uma vez que a imagem integral foi computada, o cálculo da soma das intensidades de uma dada região retangular pode ser facilmente calculada através da operação: $A + C - (B + D)$, onde A, B, C e D representam o valor dos *pixels* dos cantos da região retangular, como exibida na Figura 2.6.

A detecção dos pontos de interesse do SURF está baseada na matriz Hessiana, através da busca por estruturas parecidas onde o determinante é máximo. Dado um ponto $x = (x, y)$ em uma imagem I, a matriz Hessiana $\chi(x, \sigma)$ em x e com uma escala σ é definida por:

$$\chi(x, \sigma) = \begin{bmatrix} L_{xx}(x, \sigma) & L_{xy}(x, \sigma) \\ L_{xy}(x, \sigma) & L_{yy}(x, \sigma) \end{bmatrix} \tag{2.13}$$

Onde $L_{xx}(x, \sigma)$ é a convolução da derivada Gaussiana de segunda ordem $\frac{\vartheta^2}{\vartheta x^2} g(\sigma)$ com a imagem I em x. Da mesma forma descobre-se $L_{xy}(x, \sigma)$ e $L_{yy}(x, \sigma)$. A Fi-

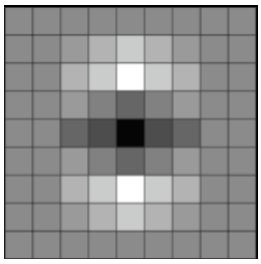

(a) Derivada Gaussiana de segunda ordem em $L_{yy}(x, \sigma)$

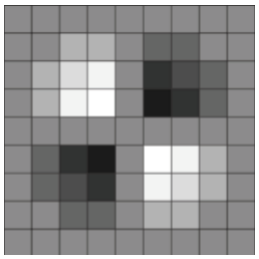

(b) Derivada Gaussiana de segunda ordem em $L_{xy}(x, \sigma)$

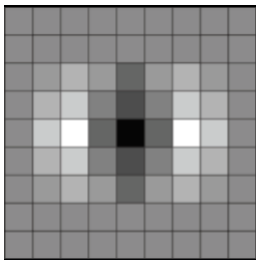

(c) Derivada Gaussiana de segunda ordem em $L_{xx}(x, \sigma)$

Figura 2.7: (a) Derivada Gaussiana de segunda ordem aplicadas em y ($L_{yy}(x, \sigma)$) , (b) Derivada Gaussiana de segunda ordem aplicadas em xy ($L_{cy}(x, \sigma)$) e (c) Derivada Gaussiana de segunda ordem aplicadas em x ($L_{xx}(x, \sigma)$)

gura 2.7(a) exibe a derivada gaussiana de segunda ordem em y ($L_{yy}(x, \sigma)$). Já a Figura 2.7(b) exibe a derivada gaussiana de segunda ordem em $xy(L_{xy}(x, \sigma))$ e a Figura 2.7(c) exibe a derivada da gaussiana de segunda ordem em x($L_{xx}(x, \sigma)$). Para todas as imagens da figura 2.7 uma escala, σ de 1.2 foi utilizada.

Já que a aplicação do filtro Hessiano original não é ideal para aplicações computacionais, um filtro Laplaciano da Gaussiana [Low04] é utilizado, de forma a transformar o resultado obtido pela aplicação da matriz Hessiana em valores computacionais. Um filtro $9x9$ normalmente é utilizado, pois adéqua-se bem a maioria dos casos. Denomina-se D_{xx} a aplicação do filtro Laplaciano da Gaussiana na Derivada Gaussiana de segunda ordem $L_{xx}(x, \sigma)$. Da mesma forma encontra-se D_{xy} e D_{yy}. O resultado da aplicação do filtro Laplaciano da Gaussiana nas imagens da Figura 2.7 pode ser visto nas imagens da Figura 2.8.

Para encontrar as regiões de interesse em um dado ponto x, o SURF utiliza o determinante da matriz Hessiana para o ponto x. Os pontos com determinantes próximos são mapeados em uma região similar, delimitando aquela como uma região de interesse. O determinante da matriz Hessiana pode ser calculado utilizando a aproximação de D_{xx}, D_{xy} e D_{yy}:

$$\det(\chi) = D_{xx}D_{xy} - (0.9D_{xy})^2 \tag{2.14}$$

As regiões de interesse encontradas precisam ser invariantes à escala, de forma que imagens com tamanhos diferentes possam ser comparadas e para tanto um espaço de escala é implementado. Espaços de escala são utilizados geralmente como uma pirâmide de imagens. A cada nível da pirâmide, a imagem é suavizada com um filtro Gaussiano e então redimensionada. Como o SURF trabalha com imagens integrais, o custo computacional de aplicar filtros maiores na mesma imagem é menor do que redimensionar toda a imagem, fazendo com que em cada nível da pirâmide seja aplicado um filtro gaussiano em escala maior. No trabalho de [Low04], ele aplica uma Diferença de Gaussianas em todos os níveis da pirâmide, de forma a extrair contornos e regiões comuns a todas elas.

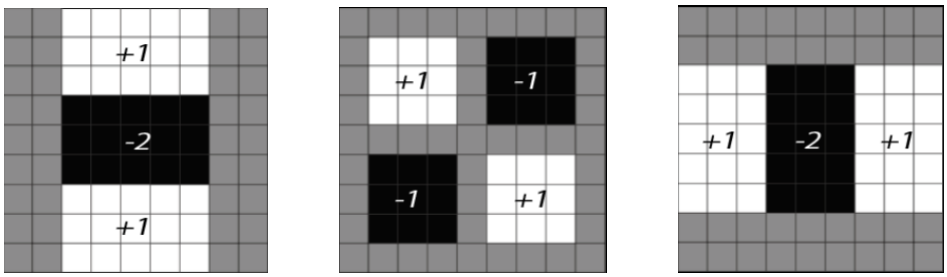

(a) Aplicação do filtro Laplaciano Gaussiana na Figura 2.7(a)

(b) Aplicação do filtro Laplaciano Gaussiana na Figura 2.7(b)

(c) Aplicação do filtro Laplaciano Gaussiana na Figura 2.7(c)

Figura 2.8: Resultado da aplicação do filtro Laplaciano Gaussiana nas imagens da Figura 2.7.

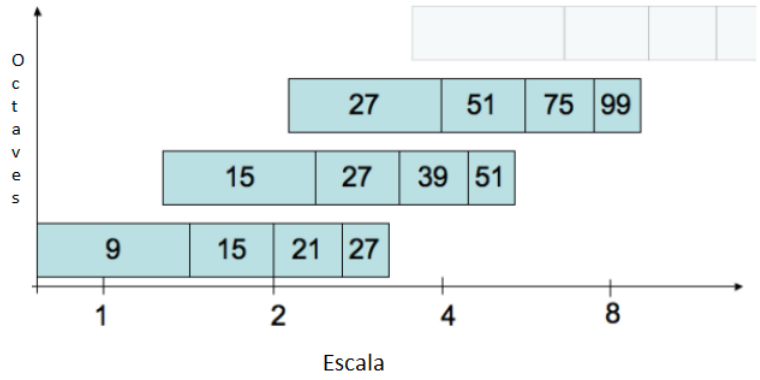

Figura 2.9: Relação entre *Octave* e as escalas de aplicação dos filtros.

Para extração dos pontos de interesse, dentro da região de interesse, o espaço de escala é dividido em *Octaves*. Cada *Octave* representa um mapeamento das respostas obtidas pela convolução da imagem com um filtro, que varia em escala. No total, uma *Octave* contém o mapeamento das respostas de um filtro com escala dobrada, ou seja, o filtro vai crescendo ate atingir uma escala que possui o dobro do tamanho original. A Figura 2.9 exibe a relação entre as *Octave* e as escalas para aplicação dos filtros em cada uma delas.

A imagem original é aplicada dentro do espaço de escalas, o filtro com escalas diferentes em cada *Octave*. Isso cria uma pirâmide de imagens, contendo a imagem original na base, e todas as suas derivadas nos níveis mais acima. A partir das áreas de regiões encontradas em cada *Octave*, uma supressão não-máxima de tamanho $3x3$ é aplicada em cada escala de cada *Octave*. Esse processo resulta na extração de intensidades díspares, realçando as regiões de transição da imagem. Para cada escala aplicada, a supressão não-máxima também é aplicada para as regiões acima e abaixo, realçando as áreas de interesse nas diversas escalas. Após essa operação, os pontos de interesse($\hat{\chi}$) são interpolados utilizando transformando a matriz Hessiana escrita no formato de uma expansão de uma série de Taylor centrada no ponto X:

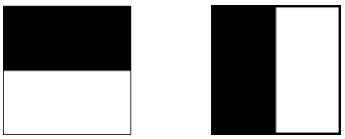

(a) Transformada de *Haar* para a direção x, denominada **Dx**.

(b) Transformada de *Haar* para a direçãoy, denominada **Dy**.

Figura 2.10: Transformada de *Haar* aplicada em ambas as direções, (a)x e (b)y

$$\hat{\chi} = -\frac{\vartheta^2 H}{\vartheta X^2}^{-1} \frac{\vartheta H}{\vartheta X} \tag{2.15}$$

Após extrair os pontos de interesse, o SURF obtém descritores para esse ponto. De forma que esses descritores sejam invariantes à rotação, o SURF extrai a orientação de cada ponto. Para tanto a transformada de *Haar* é calculada para as direções x e y para os vizinhos em um raio de $6s$, onde s delimita a escala em que os pontos foram encontrados. Mais uma vez o uso de imagens integrais auxilia na aplicação da transformada de *Haar*, agilizando o seu cálculo. A Figura 2.10 exibe a transformada de *Haar* para as direções x e y, respectivamente D_x e D_y.

Com o resultado da aplicação da transformada em todos os pontos vizinhos, separa-se os valores de Dx e Dy em um plano cartesiano e multiplica-se cada valor pela Gaussiana($\sigma = 2.5s$), onde s representa a escala, centrada no ponto de interesse. A orientação é calculada através da soma de todas as respostas que pertencem a uma janela, de tamanho previamente informado. Essa janela é deslizada, centrada no ponto de interesse, a uma taxa de $\frac{\pi}{3}$ radianos, e a orientação calculada novamente. A orientação dominante é escolhida pelo valor que obtiver maior soma das coordenadas.

Para extrair a descrição de cada ponto de interesse, o primeiro passo é construir uma região quadrada, de tamanho $20s$, onde s é a escala, centrada no ponto de interesse e com a orientação baseada na orientação do ponto de interesse. Essa região é dividida em pequenas subregiões de tamanho $5x5$. A transformada de *Haar* de cada pixel de cada subregião é calculada, para ambas as direções, x e y, sempre orientadas pelo ponto de interesse. Para cada conjunto de $4x4$ um vetor de descrição com quatro dimensões é extraído. Esse vetor é composto pela soma do valor da transformada de *Haar* de cada pixel da região, em ambas as direções, e a soma do valor absoluto para cada dimensão. Isso é necessário para trazer informações sobre mudança de intensidades, na vizinhança do ponto de interesse. o vetor de descritores para cada sub-região, denominado v, é definido como:

$$v = \left(\sum Dx, \sum Dy, \sum |Dx|, \sum |Dy|\right) \tag{2.16}$$

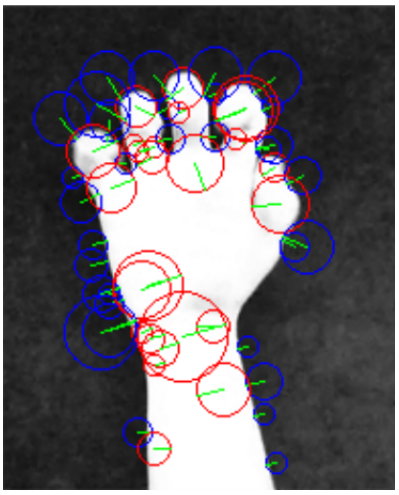

Figura 2.11: Extração dos pontos de interesse e orientação aplicadas à Figura 2.2(a).

Para todas as subregiões presentes na região, um vetor contendo 64 características é extraído, já que a cada subregião, com tamanho $5x5$, um vetor com 4 características é extraído. Esse vetor contendo 64 elementos é o descritor do ponto de interesse. A Figura 2.11 exibe a aplicação da extração de pontos de interesse e a orientação desses pontos aplicados à imagem da Figura 2.2(a).

Para o reconhecimento de gestos dinâmicos, o SURF apresenta um problema crônico: a quantidade de características extraídas é muito elevada. Se para cada ponto de interesse são extraídas 64 características, uma imagem como a Figura 2.11, que contém 57 pontos, conteria um total de 3648 características. No reconhecimento de gestos dinâmicos, um gesto é formado por uma sequência de imagens, então um gesto contendo 15 imagens com posturas diferentes precisaria de 54.720 características para representá-lo. Esse valor se mostrou de grande magnitude para todos os classificadores implementados nessa dissertação, diminuindo a taxa de reconhecimento e aumentando o tempo de processamento.

2.3.4 Algoritmo SURF

O algoritmo do SURF, Algoritmo 3, começa com a transformação da imagem em uma imagem integral, como exibido na linha 1. Depois disso, as *Octavas* são extraídas, através da aplicação de várias convoluções entre a matriz Hessiana e a imagem integral, exemplificado na linha 2. Depois de obtidas as *Octavas*, os pontos de interesse são extraídos, através da aplicação de supressões não-máximas em um espaço de escalas formado por variações da imagem original aplicadas à um filtro Gaussiano com escala variante. Os pontos são interpolados utilizando uma expansão da série de Taylor centrada no ponto X, essa operação está exemplificada nas linhas 3 à 6.

A orientação dos pontos de interesse é obtida através da soma da aplicação de uma série de transformadas de *Haar* dos eixos x e y nos vizinhos, pertencentes

a uma determinada janela, do ponto de interesse. Ao rotacionar a janela, várias somas são obtidas e a soma que tiver o maior valor é escolhida como orientação do ponto de interesse. Esse processo é demonstrado nas linhas 6 à 9.

Para cada ponto de interesse encontrado, são extraídos 64 descritores, que são a soma e soma absoluta das transformadas de *Haar* para os eixos x e y para cada grupo de $5x5$ vizinhos. As linhas 10 à 13 exemplificam esse processo.

Algorithm 3: Algoritmo para extração de descritores de imagem utilizando SURF

```
1  ImagemIntegral = ImagemIntegral(Imagem);
2  List<Octavas> Octavas = ExtrairOctavas(ImagemIntegral);
3  List<PontoInteresse> pontosInteresse; for Octava octava em Octavas do
4  |  pontosInteresse.add(ExtrairPontosInteresse(octava));
5  end
6  for PontoInteresse ponto em pontosInteresse do
7  |  ponto.add(ExtrairOrientacao(ponto));
8  end
9  for PontoInteresse ponto em pontosInteresse do
10 |  ponto.add(ExtrairDescritores(ponto));
11 end
12 return pontosInteresse.
```

2.4 Reconhecimento de Padrões

O Segundo módulo de um sistema de reconhecimento de gestos é o módulo de classificação. Neste módulo técnicas de reconhecimento de padrões capazes de classificar um gesto dinâmicos a partir das características extraídas pelas técnicas de extração são utilizadas. Três técnicas foram escolhidas para serem utilizadas nesse trabalho, e são debatidas nos tópicos a seguir: Modelos Ocultos de Markov, *Dynamic Time Warping* e Redes Neurais Recorrentes.

Essas técnicas foram selecionadas devido à sua natureza para reconhecimento de padrões que evoluem com o tempo. [MT91] utiliza uma rede recorrente de elman para o reconhecimento de posturas de mão que representam 42 símbolos da língua japonesa de sinais. [MAZ08] utiliza uma rede neural recorrente para o reconhecimento de gestos presentes na Lingua Árabe de Sinais. Já [SHL+98] utiliza uma rede neural recorrente para o reconhecimento de gestos baseados em *templates* espaciais, onde os gestos devem ser realizados em uma área pré-definida de frente à câmera de vídeo.

[AL06] utiliza o contorno de um ser humano para descrever posições corporais e as classifica utilizando um HMM. Já [ATK11] desenvolveu um sistema que utiliza um HMM para cada gesto presente na Língua Malasiana de Sinais, podendo reconhecer os gestos realizados pela mão do usuário.

2.4.1 Modelos Ocultos de Markov - HMM

Os Modelos Ocultos de Markov (HMM), são métodos estocásticos *Markovianos* que geram observáveis de forma indireta, como descrito por [Rab90]. Para compreender melhor um HMM é necessário um entendimento preliminar sobre as cadeias de Markov. Modelos de Markov são processos estocásticos onde a probabilidade de um determinado evento ocorrer depende somente do estado atual da variável observada [DdM10]. Já HMMs são considerados processos duplamente estocásticos, já que o que são observados não são as transições entre estados e sim um determinado sinal que a variável emite estando em um estado.

Em um HMM a evolução do sistema é observada de forma indireta, captando-se o comportamento dos observáveis, ou seja, o sinal emitido pela variável ao passar por um determinado estado. Dessa forma não é possível saber o caminho ou sequência de passos exatos pela qual a variável percorreu o sistema, mas é possível classifica-la pelos observáveis que ela emite, através de uma função probabilística de transição entre os estados definidos num espaço de estados discreto e finito.

Um HMM pode ser definido por λ:

$$\lambda = (A, B, \pi) \tag{2.17}$$

Dado um HMM com um número finito de estados, A representa sua matriz de probabilidades de transições entre os estados. Cada elemento a_{ij} da matriz representa a probabilidade de saída do estado i para o estado j. Já π é o vetor de probabilidades de distribuição inicial, onde cada elemento i representa a probabilidade do estado inicial ser i. B representa o conjunto de probabilidade dos observáveis, onde cada elemento b_{ij} representa a probabilidade do observável j ser emitido no estado i. Essa matriz pode ser composta por valores discretos ou por distribuições contínuas, como por exemplo na aplicação para reconhecimento de gestos dinâmicos, onde cada observável passa a ser um gesto executado. A distribuição contínua padrão utiliza um conjunto de k distribuições normais $g_{jk}(x)$ e k pesos c_{jk}, onde a probabilidade de emissão é dada por $b_{jk} = \sum_k c_{jk} g_{jk}(x)$ A Figura 2.12 exibe uma representação gráfica de um HMM composta por três estados $(x1, x2ex3)$ e o conjunto de observáveis que podem ser emitidos $(y1, y2ey3)$.

Para poder classificar uma sequência de observáveis emitida por um HMM, uma sequência de procedimentos é utilizada. Essa sequência resolve os denominados três problemas canônicos, ou fundamentais [Rab90]. Através da solução desses três problemas é possível obter uma sequência de observáveis ao se inserir uma variável em um HMM, classificar essa sequência de observáveis e maximizar a probabilidade de uma sequência de observáveis, calibrando o modelo para a tarefa de classificação. A definição desses problemas é dada abaixo:

- O primeiro problema procura responder a seguinte questão: Dada a sequência de observáveis O = O_1,O_2,...O_n, como calcular de forma eficiente a probabilidade dessa sequência ser gerada gerada pelo modelo $\lambda = (A, B, \pi)$, $P(O \mid \lambda)$?

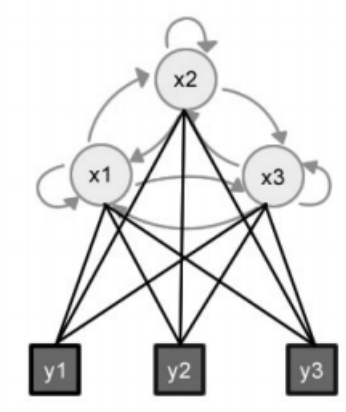

Figura 2.12: Representação gráfica de um HMM contendo três estados ($x1, x2ex3$) e os observáveis que podem ser emitidos por eles ($y1, y2ey3$)

- Já o segundo problema procura a resposta para: Seja um modelo $\lambda = (A, B, \pi)$ e uma sequência de observáveis O = O_1,O_2,...O_n, qual a mais provável sequência de estados que poderiam ter gerado esses observáveis?
- O último problema, denominado *Training* procura responder a pergunta: Qual melhor ajuste dos parâmetros do modelo $\lambda = (A, B, \pi)$ para maximizar $P(O \mid \lambda)$?

Para cada um desses problemas, um algoritmo diferente é utilizado. Para resolução do primeiro problema, o algoritmo *Forward-Backward* é o mais indicado [LEBW70]. Nesse algoritmo uma variável *Forward* ($\alpha_t(i)$) representa a probabilidade de que para um determinado modelo λ a primeira sequência de observáveis até O_t é gerada ao tempo t e o estado i é alcançado:

$$\alpha_t(i) = P(O_1, O_2, ..., O_3, S_t = i \mid \lambda) \tag{2.18}$$

Ou seja, a probabilidade parcial dos observáveis, de O_1 até O_t, conjunta com a probabilidade de ocupação do estado S_i no tempo t. Como trabalha-se com sequências em função do tempo, pode-se dizer que trabalha-se com conjuntos ordenados de eventos, o que implica dizer que $\alpha_t(i)$ vale para qualquer instante de tempo dentro do intervalo $0 \leq t \leq T$, onde t representa o tempo parcial de observação e T o tempo total. Para calcular os diversos valores de $\alpha_t(i)$ o seguinte procedimento é aplicado:

- Inicialização:

$$\alpha_0(i) = \pi_i \tag{2.19}$$

  Onde i varia de 1 até a quantidade total de estados.

- Indução:

$$\alpha_{t+1}(j) = \sum_{i=1}^{N} \alpha_t(i)\alpha_{ij}b_{ij}(O_{t+1}) \tag{2.20}$$

Onde j varia de 1 até a quantidade total de estados, N e t varia de 0 até o $T-1$.

- Finalização:

$$P(O\lambda) = \sum_{i=1}^{N} \alpha T(i) \tag{2.21}$$

Já as variáveis $\beta_t(i)$, denominadas *Backward*, representam a probabilidade de gerar a sequência parcial de observáveis O_{t+1}, O_{t+2},...,O_T a partir do tempo $t+1$ iniciando em $S_t(i) = 0$ em um determinado modelo λ. Ou seja, a probabilidade de estar no estado S_i no instante t com a probabilidade da sequência parcial de observáveis após t ter sido emitida:

$$\beta_t(i) = P(O_{t+1}, O_{t+2}, ...O_T \mid q_t = S_i, \lambda) \tag{2.22}$$

Para calcular os diversos valores de $\beta_t(i)$ deve-se utiliza o seguinte procedimento:

- Inicialização:

$$\beta T(i) = 1 \tag{2.23}$$

Onde i varia de 1 até a quantidade total de estados.

- Indução:

$$\beta_t(i) = \sum_{j=1}^{N} \alpha_{ij} b_{ij}(O_{t+1}) \beta_{t+1}(j) \tag{2.24}$$

Onde t começa de $T-1$ e segue sempre sendo decrescido de 1 até atingir 0, e i varia de 1 até a quantidade total de estados.

A partir de qualquer uma das duas variáveis, $\alpha_t(i)$ e $\beta_t(i)$, é possível calcular a probabilidade da sequência O ter sido emitida pelo modelo λ:

$$P(O \mid \lambda) = \sum_{i=1}^{N} \alpha_T(i) \tag{2.25}$$

$$P(O \mid \lambda) = \sum_{i=1}^{N} \pi i b i(O_1) \beta_1(i) \tag{2.26}$$

Para a solução do segundo problema, o algoritmo de *Viterbi* [For73] é utilizado. O algoritmo de *Viterbi* ajuda a achar a mais provável sequência completa de estados$Q$ que pode ter gerado uma sequência de observáveis O, ou seja maximizar $P(Q \mid O, \lambda)$. Para tanto segue-se a seguinte definição:

$$\delta_t(j) = \max_{q_1, q_2 ... q_{t-1}} P\left[q_1, q_2, ..., q_t = S_j, O_1 O_2 ... Ot \mid q_0 = S_i, \lambda\right] \tag{2.27}$$

Onde $\delta_t(j)$ representa a probabilidade da sequência de estados mais prováveis que leva ao estado S_j no instante t, gerando os primeiros t observáveis. Utilizando o vetor $\psi_t(k)$ para armazenar a sequência de estados no tempo t, o algoritmo de *Viterbi* é executado seguindo procedimento a seguir:

- Inicialização

$$\delta_1(j) = a_{ij} b_{ij}(O_1) \tag{2.28}$$

$$\psi 1(j) = 0 \tag{2.29}$$

  Onde j varia de 1 até a quantidade de estados.

- Indução

$$\delta_t(k) = \underset{1 \leq j \leq N}{max} \left[\delta_{t-1}(j) a_{jk} b_{jk}(O_t)\right] \tag{2.30}$$

$$\psi 1(j) = \underset{1 \leq j \leq N}{argmax} \left[\delta_{t-1}(j) a_{jk}\right] \tag{2.31}$$

  Onde t varia de 2 até T, sendo T o tempo total e K varia de 1 até o total de estados, N.

- Finalização

$$P = \underset{1 \leq k \leq N}{max} \left[\delta_T(k)\right] \tag{2.32}$$

$$Q*_T = \underset{1 \leq k \leq N}{max} \left[\delta_T(k)\right] \tag{2.33}$$

Para recriar o caminho para a melhor sequência, ou seja, aquela que obter o P máximo, basta realizar a seguinte operação:

$$Q*_t = [\psi t + 1, \{Q*_{t+1}\}] \tag{2.34}$$

Para t começando de $T-1$ e diminuindo unitariamente até atingir 1. Após essa operação $Q*$ armazenará o caminho mais adequado. Caso ao final do algoritmo, mais de uma sequência possua a mesma probabilidade de ocorrência, uma delas é selecionada arbitrariamente.

O ultimo problema utiliza o algoritmo de *Baum-Welch* [LEBW70]. Esse algoritmo consegue otimizar os parâmetros do HMM , de forma que ele possa maximizar a probabilidade de gerar uma sequência completa de observáveis, $P(O \mid \lambda)$. O algoritmo de *Baum-Welch* funciona otimizando a probabilidade de determinada sequência ter sido gerada pelo modelo, portanto em cada iteração ele deve gerar um novo conjunto de parâmetros que otimize a probabilidade obtida pela iteração anterior.

Os valores atualizados de cada parâmetro são calculados com base em três funções: Probabilidade posterior para ocorrência do estado i no tempo t, denominada $\gamma(i)$, Probabilidade posterior da transição de um estado i para um estado j no tempo t, denominada $\gamma(i,j)$ e a Probabilidade de selecionar no estado j o k-ésimo componente da distribuição de probabilidade no tempo t para gerar a observação contínua O_t, denominada $\varepsilon(j,k)$. Essas três funções são definidas como:

$$\gamma(i) = P(S_t = i \mid O, \lambda) = \frac{\alpha_t(i)\beta_t(i)}{P(O \mid \lambda)} \tag{2.35}$$

$$\gamma(i,j) = P(S_t = i, S_{t+1} = j \mid O, \lambda) = \frac{\alpha_t(i)a_{ij}b_{ij}(O_{t+1})\beta_{t+1}(j)}{P(O \mid \lambda)} \tag{2.36}$$

$$\varepsilon(j,k) = P(S_t = j, M_t = k \mid O, \lambda) = \frac{\sum_{i=1}^{N} \alpha_t(i)a_{ij}c_{jk}g_{jk}(O_t)\beta_t(j)}{P(O \mid \lambda)} \tag{2.37}$$

Para a otimização dos parâmetros, o algoritmo de *Baum-Welch* utiliza os seguintes procedimentos:

- Inicialização

  Um modelo inicial $\lambda = (A, B, \pi)$ é definido, contendo estimativas iniciais para cada parâmetro.

- Otimização

  A atualização de cada parâmetro é calculada para a criação de um novo modelo, $\lambda' = \{A', B', \pi'\}$. Para cada elemento, a_{ij} da matriz A', têm-se:

  $$a_{ij} = \frac{\sum_{t=1}^{T-1} \gamma_t(i,j)}{\sum_{t=1}^{T-1} \gamma_t(i)} \tag{2.38}$$

  Já o valor do vetor π' é atualizado através da seguinte operação:

  $$\pi' = \gamma_1(i) \tag{2.39}$$

  Cada valor dos pesos c das distribuições de probabilidade, assim como μ' e C' são calculados como:

  $${c_{jk}}' = \frac{\sum_{t=1}^{T} \varepsilon_t(j,k)}{\sum_{t=1}^{T} \gamma_t(j)} \tag{2.40}$$

  $${\mu_{jk}}' = \frac{\sum_{t=1}^{T} \varepsilon_t(j,k)x_t}{\sum_{t=1}^{T} \varepsilon t(j,k)} \tag{2.41}$$

  $$Cjk' = \frac{\sum_{t=1}^{T} \varepsilon_t(j,k)x_t(x_t^T)}{\sum_{t=1}^{T} \varepsilon t(j,k)} - {\mu_{jk}}'{\mu_{jk}^T}' \tag{2.42}$$

- Validação

  Alguns parâmetros para finalização da etapa de otimização devem ser escolhidos, como um número x de iterações atingida ou uma melhora muito grande. Ao atingir essa condição de parada, garante-se que o modelo está otimizado.

Os HMMs vem sendo utilizados para a classificação de padrões temporais, como citado anteriormente, e uma dessas aplicações é para o reconhecimento de gestos dinâmicos. Neste trabalho, o HMM apresenta bons resultados, como exibidos no capítulo 4.

2.4.2 Algorítmo HMM

O Algoritmo do HMM, Algoritmo 4, começa com a definição de uma base de dados para treino, a ser utilizada na otimização dos parâmetros do modelo. Um novo modelo, com os parâmetros iniciais escolhidos aleatoriamente, é criado, como indicado na linha 3. Até que uma determinada condição de parada não seja atingida, sendo essa condição uma determinada quantidade de iterações, por exemplo, o algoritmo de*Baum-Welch* otimiza os valores dos parâmetros do modelo, como indicados entre as linhas 4 a 8. A classificação de um novo padrão, como delimitado na linha 9, utiliza os algoritmos *Feed-Forward* e *Viterbi* para definir quais foram os observáveis gerados pelo dado a ser classificado, e a qual classe esses dados pertencem.

Algorithm 4: Algoritmo para execução e treino de um modelo HMM

```
1 Dados dadosTreino;
2 Dados dadoASerClassificado;
3 HMM hmm = NovoHMM();
4 while condição de parada não for atingida do
5 |   HMM hmm' = BaumWelch(HMM);
6 |   if(hmm'.erro(baseTreino) > hmm.erro(baseTreino)) hmm = hmm';
7 end
8 Classe classificacao = hmm.classifica(dadoASerClassificado);
9 return classificacao.
```

2.4.3 Dynamic Time Warping - DTW

Dynamic Time Warping (DTW) é uma técnica para encontrar o melhor alinhamento entre duas sequências, não necessariamente possuindo o mesmo tempo e espaço. O DTW vem sendo utilizado na área de reconhecimento de voz, mas algumas recentes aplicações utilizam sua capacidade de comparação entre sequências para o reconhecimento de gestos dinâmicos.

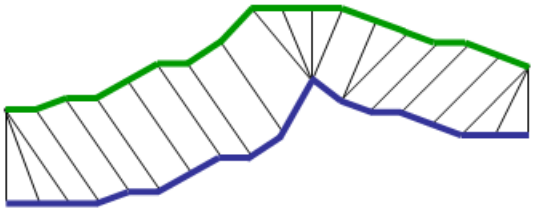

Figura 2.13: Duas sequências com tamanhos diferentes sendo alinhadas utilizando o DTW.

O objetivo primário do DTW é a comparação de duas sequências $X = (x_i,x_2, x_3,...,x_N)$ de tamanho N, e $Y = (y_i,y_2, y_3,...,y_N)$ de tamanho M. Essas sequências podem ser sinais discretos ou uma sequência de características dinâmicas, extraídas de padrões que evoluem com o tempo. Para calcular a distância entre essas duas sequências , X e Y, uma medida de custo local, denominada c é necessária. Normalmente c possui um valor menor quando X e Y são parecidas e um valor maior quando são muito diferentes. Uma matriz de custo C é definida pela diferença de cada par de elementos presente em X e Y, ou seja cada elemento a_{ij} é composto pela diferença entre o elemento i de X e o elemento j de Y,e o objetivo do DTW é encontrar o melhor alinhamento para X e Y, obtendo o menor custo para a matriz C. A Figura 2.12 exibe o alinhamento entre duas sequências de tamanhos diferentes, utilizando o DTW.

O DTW define como $P = (p_1, p_1...,p_L)$ como o caminho de menor custo da matriz C, onde $p_l = a_{ij}$. A Figura 2.13 exemplifica a matriz de custos C para duas sequências. Para tanto, P tem que satisfazer as seguintes condições:

- Monotonicidade: O caminho percorrido não pode voltar no tempo, ou seja, p_{x+1} está sempre à frente de p_x. Essa condição garante que não existam elementos com distâncias repetidas. Isso implica dizer que: $n_1 \leq n_2 \leq ... \leq n_L$ e $m_1 \leq m_2 \leq ... \leq m_L$.

- Continuidade: O caminho percorrido não pode saltar no tempo. Isso quer dizer que p_{x+1} está sempre uma unidade à frente de p_x. Isso garante que todos os elementos sejam computados na escolha do menor custo.

- Limites: a verificação de alinhamento começa sempre da extrema esquerda, na parte de baixo, ou seja p_1=(1,1) e termina sempre na extrema direita na parte de cima, ou seja $p_L = (n,m)$.

- Janela de deformação: O alinhamento não pode ficar muito distante da diagonal, garantindo que o alinhamento não tente pular distâncias muito grandes ou que fique preso em distâncias muito próximas.

O custo total, $c_p(X, Y)$ é dado como a soma de todos os elementos do caminho P:

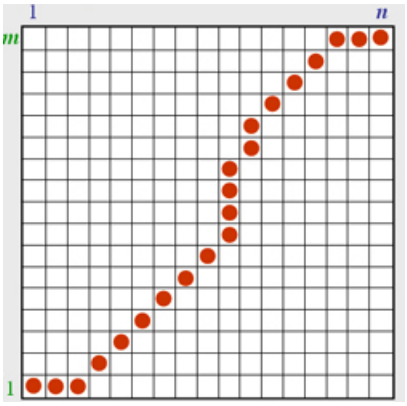

Figura 2.14: Duas sequências com tamanhos diferentes sendo alinhadas utilizando o DTW.

$$c_p(X, Y) = \sum_{l=1}^{L} P(l) \tag{2.43}$$

2.4.4 Algoritmo DTW

No algoritmo do DTW, Algoritmo 5, duas sequências X e Y são definidas, e a matriz de distâncias entre elas é calculada, para cada elemento de X e de Y, como exibido entre as linhas 1 e 6. Depois do cálculo da matriz, o vetor com a menor distância é encontrada, utilizando as condições definidas pelo DTW, como exibida na linha 9.

Algorithm 5: Algoritmo para execução do cálculo de distâncias através do DTW

```
1  Sequencia X;
2  Sequencia Y;
3  MatrizCusto C;
4  for Cada elemento x_i em X do
5  |   for Cada elemento y_j em X do
6  |   |   C_ij = distancia(x_i, y_j);
7  |   end
8  end
9  MenorDistancia P = menorDistancia(C);
10 return P.
```

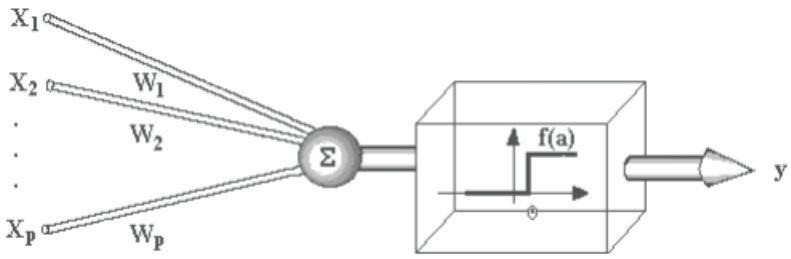

Figura 2.15: Representação gráfica de um peceptron, onde X_1, X_2, X_p representam as entradas,W_1,W_2, W_p representam os pesos, $\sum$ representa a função soma e f(a) representa o limiar de ativação.

2.4.5 Rede Neural Recorrente de Elman - Elman RNN

Redes Neurais vem sendo utilizadas na área de reconhecimento de padrões a muito tempo. Sua capacidade de generalização, treinamento para novos padrões e robustez de resultados garantem sua funcionalidade para várias aplicações, entre elas reconhecimento de gestos. Um dos problemas envolvidos em reconhecimento de gestos dinâmicos é a composição do gesto, formado por várias posições de uma mão que variam com o tempo. Para esse problema, uma rede neural *Multilayer Perceptron* não é indicada, pois ela não é capaz de reconhecer padrões em um fluxo de tempo. Para tanto, uma rede neural recorrente é mais indicada.

Para compreender uma rede neural recorrente, é necessário o entendimento do conceito de rede neural multi-camadas, a *Multilayer Perceptron* (MLP). Uma MLP é uma rede neural composta por neurônios artificiais, perceptrons, interligados e compondo várias camadas. Um perceptron simula o funcionamento de um neurônio biológico, assim sendo os dendritos foram substituídos por entradas, cujas ligações com o corpo celular artificial são realizadas através de elementos chamados pesos, simulando as sinapses. Os estímulos captados pelas entradas são processados pela função de soma e o limiar de disparo do neurônio biológico foi substituído pela função de transferência [Ros]. A Figura 2.15 exibe uma ilustração de um perceptron.

Um perceptron exibe um saída baseada na soma das suas entradas e se o resultado dessa soma atinge ou não um determinado limiar. Ele é capaz de separar linearmente vetores de entrada em classes de padrões através de hiperplanos. A função soma, a, é definida pela soma das entradas, X, ponderadas pelos pesos, W. Cada entrada representa um elemento no vetor de características que se quer classificar e uma entrada a mais é adicionada, denominada *bias*, que possui sempre valor 1 e serve como uma forma de ajustar o desvio dos pesos de um perceptron.

$$a = \sum_{i=0}^{p} X_i W_p \tag{2.44}$$

Onde p é a quantidade total de entradas para o neurônio. O resultado dessa função é comparado com um limiar previamente definido , l, e o resultado expelido

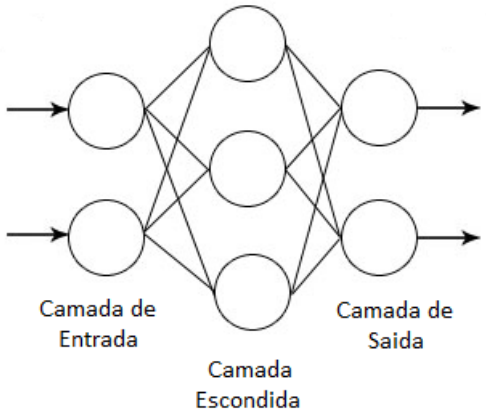

Figura 2.16: Representação gráfica de uma MLP contendo as camadas de entrada, uma camada escondida e a camada de saída.

pela saída do neurônio. A função $f(a)$ delimita o limiar de ativação do perceptron:

$$f(a) = \begin{cases} 1, a > l \\ 0, a \leq l \end{cases} \tag{2.45}$$

Para a classificação de padrões mais complexos, uma arquitetura com vários perceptrons dispostos em camadas é utilizada, a MLP. Por convenção a primeira camada dessa arquitetura é denominada camada de entrada, as camadas subsequentes são chamadas de camadas escondidas e a última camada é denominada camada de saída[Hay99].

Cada camada de uma MLP é formada por um ou mais perceptrons. A entrada de cada camada é dada pela saída dos neurônios na camada anterior, exceto na camada de entrada, onde a entrada é dada por cada elemento do vetor de características que se deseja classificar. Cada valor do vetor de características deve ser passado a um neurônio na camada de entrada e a saída desses neurônios são propagadas para todos os neurônios da camada subsequente até que cheguem à camada de saída. A Figura 2.16 exibe a arquitetura de uma MLP.

Nas camadas escondidas de uma MLP, uma função de ativação,$f(a)$, é utilizada para delimitar a saída de cada neurônio. A função sigmoide é muito utilizada para a maioria dos casos de classificações, sendo definida como:

$$f(a) = \frac{1}{1 + \varepsilon^{-\lambda a}} \tag{2.46}$$

Em outros casos essa função também pode ser escrita como segue:

$$f(a) = \frac{1}{2} + \frac{1}{2} tanh\left(\frac{\lambda a}{2}\right) \tag{2.47}$$

Em uma rede neural o conhecimento para classificação esta armazenado diretamente nos pesos das ligados a cada entrada. Isso implica dizer que um conjunto de

pesos precisa ser escolhido para o sistema de forma que a rede possa classificar os padrões corretamente, para isso o algoritmo *Backpropagation*, explicado de forma simples por [MAZ08], é o mais indicado.

O *Backpropagation* consiste em um algoritmo que encontra a melhor distribuição de pesos para uma rede neural, dado um certo conjunto de dados. Ou seja, para um conjunto de dados de treinamento, ele encontra os pesos que possibilitam que a rede neural generalize uma nova entrada, classificando-a. Para tanto ele utiliza o conceito de retropropagação do erro pela rede, ajustando os pesos quando necessário. Para tanto ele realiza o seguinte procedimento:

- Inicialização. Todos os pesos dos neurônios na rede são inicializados com valores aleatoriamente escolhidos no intervalo [1,-1].

- Exemplos de treino. Um conjunto de dados é selecionado para para se treinar a rede, ou seja, a rede irá ser ajustada de acordo com esse conjunto de treino. Esse conjunto, T, é composto pelos vetores de características , x, e a saída esperada para esse vetor de características, d. Assim T é definido por:

$$T = x_1, d_1, x_2, d_2, ..., x_n, d_n \tag{2.48}$$

- Propagação. Utilizando cada entrada x do conjunto de treino calcule a saída da rede neural, $O_j(x)$. A saída é dada pela função de ativação da camada de saída, j.

- Calculando o sentido do erro da rede. Utilizando a saída $O_j(x)$, o sinal do erro $e_j(x)$ é dado por:

$$e_j(x) = d_j(x) - O_j(x) \tag{2.49}$$

  $d_j(x)$ representa a saída esperada da rede. Esse sinal será utilizado para calcular os valores dos erros nas camadas anteriores e fazer a correção dos pesos.

- Retropropagação

  Para cada neurônio, os erros locais σ são calculados. Esse erro é calculado a partir da camada de saída e é propagado em ordem inversa ate a camada de entrada. O erro local para a camada de saída é calculado como:

$$\sigma_j(x) = e_j(x)O_j(x)(1 - O_j(x)) \tag{2.50}$$

  Já para as demais camadas o erro é calculado como:

$$\sigma_j(x) = O_j(x)(1 - O_j(x)) \sum \sigma_k w_{jk} \tag{2.51}$$

  Onde σ_k representa o erro dos neurônios das camadas anteriores que estão conectados ao neurônio j, e w_{jk} representa o peso anexados a essas conexões.

Depois de calcular o erro para todos os neurônios, o ajuste dos pesos é necessário. Para tanto, o valor do peso atual w_{jk} é alterado pelo valor da correção do peso Δw_{jk}, onde Δw_{jk} é definido por:

$$\Delta w_{jk} = \alpha w_{jk} + \eta \sigma_j O_j(x) \tag{2.52}$$

Onde α é a constante de *momentum* que determina o efeito das mudanças passadas dos pesos na direção atual do movimento no espaço de pesos. η é a taxa de aprendizado, uma constante no intervalo [1,0], que indica quão rápido o modelo aprende a generalizar os exemplos passados. σ_j representa o erro no neurônio j, calculado anteriormente e $O_j(x)$ a saída do neurônio.

- Iteração.

  Após o ajuste do peso para um elemento do conjunto de treino, outro elemento é passado para um novo ajuste. Essa iteração ocorre até que a taxa de erro total da rede seja menor que um determinado limiar ou que um número máximo de ciclos de ajuste ocorram. Essa condição é denominada condição de parada e deve ser escolhida com cuidado pois uma rede pode ser treinada até que ela apresente um erro 0 para os padrões exibidos. Essa condição é denominada *overfiting* o que quer dizer que a rede superajustou os pesos, decorando os melhores pesos para os padrões dados, fazendo com que a capacidade de generalização de um novo padrão seja prejudicada. Outra condição, denominada *underfiting*, pode acontecer quando o ajuste dos pesos é parado antes que a rede possua a capacidade de generalizar os padrões, fazendo com que a classificação de um novo padrão seja dada incorretamente.

Para o reconhecimento de um padrão estático uma rede do tipo MLP se mostra ideal, mas para o reconhecimento de um padrão que evolui em uma determinada linha de tempo, uma MLP não é indicada. Para tanto, uma rede neural recorrente é a escolha mais acertada. Uma rede neural recorrente é uma MLP com uma camada a mais, denominada camada de recorrência ou contexto, que permite que a rede consiga generalizar padrões que são dependentes entre si.

Uma das redes neurais mais utilizadas para o reconhecimento de gestos é a Rede Recorrente de Elman(Elman RNN), descrita de forma clara em [Jai01]. Uma Elman RNN define uma nova camada de contexto, onde cada neurônio dessa nova camada recebe como entrada um neurônio na camada escondida. A saída desse neurônio na camada de contexto é utilizada como entrada no neurônio na camada escondida para o próximo padrão. A Figura 2.17 exibe uma Elman RNN graficamente.

Essa camada de contexto na Elman RNN garante que o padrão anterior vai influenciar na classificação do padrão atual. A propagação dos padrões na rede funciona da mesma forma que em uma MLP, sendo que uma janela de padrões é definida para ser classificados. Por exemplo, um gesto dinâmico é composto por 15 posições de mão. Para classifica-lo com uma Elman RNN, é necessário que as

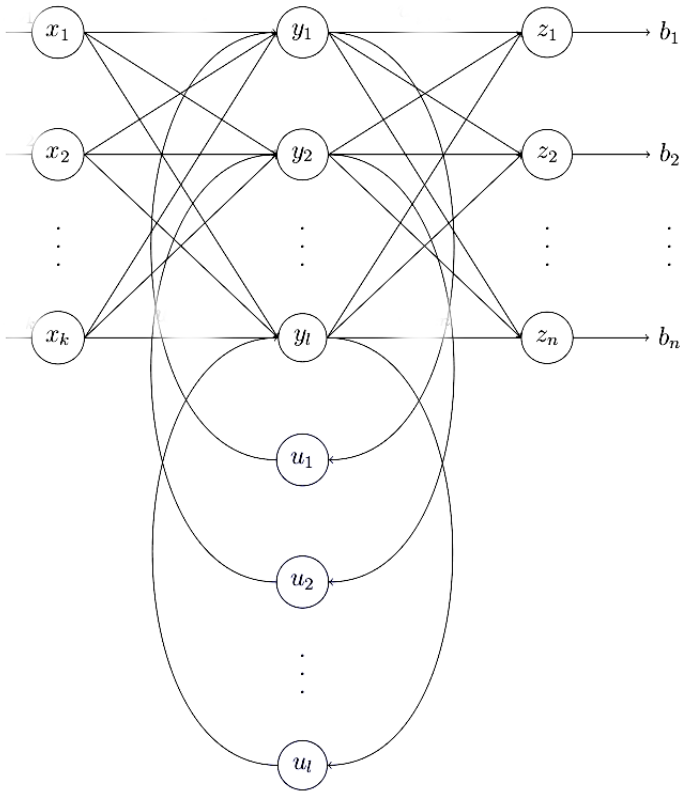

Figura 2.17: Representação gráfica de uma MLP contendo as camadas de entrada, uma camada escondida e a camada de saída.

quinze posições sejam passadas pela rede, uma de cada vez, e ao final da 15ª o padrão é classificado.

Outra grande diferença da Elman RNN é no treinamento. O algoritmo *Backpropagation* não funciona muito bem para esse fluxo de padrões, ficando preso em mínimos locais na sua execução. Para resolver tal problema , [ZWD11] utiliza a técnica *Simulated Annealing* para gerar um espaço de busca maior, retirando o *Backpropagation* dos mínimos locais encontrados. A mesma técnica pode ser vista no trabalho de [AAC+91].

Annealing é uma técnica utilizada para fundição de metais, onde este é aquecido a uma temperatura elevada e em seguida resfriado lentamente, de modo que o produto final seja uma massa homogênea. *O Simulated Annealing* [KGV83] se baseia nos princípios do *Annealing* para problemas de otimização combinatória. Nesse contexto, o processo de otimização, $min_x f(x)$ é realizado em níveis, simulando os níveis de temperatura do resfriamento. Em cada nível, dado um ponto μ, vários pontos na vizinhança de μ são gerados e o correspondente valor de f é calculado. Cada ponto é aceito ou rejeitado de acordo com certa probabilidade. Essa probabilidade de aceitação decresce de acordo com o nível do processo, ou equivalente, de acordo com a temperatura.

A ideia por trás da utilização do *Simulated Annealing* no *Backpropagation* para a Elman RNN é evitar os mínimos locais. Então, quando o *Backpropagation* atingir um ponto de estabilização no erro, o *Simulated Annealing* é executado, procurando por pontos próximos, e aumentando o nível da busca, até que o erro diminua, evitando o mínimo local. No contexto do *Simulated Annealing*, os parâmetros otimizados são os parâmetros passados para o *Backpropagation*, cada nível de temperatura representa um novo erro obtido com os parâmetros do *Backpropagation*, ou seja, no local de aumentar o nível de temperatura, o algoritmo do *Simulated Annealing* tentará diminui-lo, diminuindo o erro obtido.

2.4.6 Algoritmo Elman RNN

O algoritmo da Elman RNN, Algoritmo 6, começa com a seleção de um conjunto de dados para treino, e a definição de suas saídas esperadas, como exibidos nas linhas 1 e 2. Após a criação do modelo, o *Backpropagation* é utilizado para treinar o modelo, ajustando os pesos de acordo com o conjunto de treino e as saídas esperadas. Esse treino ocorre até que uma condição de parada seja definida. Caso o *Backpropagation* esteja preso em um mínimo local, ou seja, o erro não diminui, o *Simulated Annealing* é chamado, expandindo a área de busca. O *Simulated Annealing* precisa de uma condição de parada, já que pode-se ter sido atingido um mínimo global. Esse procedimento está exibido entre as linhas 4 a 14. Após o treinamento, um novo padrão é propagado pela rede, a a saída é considerada sua classificação, exemplificado na linha 16.

Algorithm 6: Algoritmo para treino e execução de uma Elman RNN.

```
1  List<Dados> Treino;
2  List<Classe> SaidasEsperadas;
3  RNN rnn = construirModelo();
4  for Dado i em Treino do
5  |   while condição de parada do
6  |   |   Erro = rnn.Backpropagation(i, SaidasEsperadas(i));
7  |   |   while Erro não diminui ou a condição de parada do Simulated
   |   |   Annealing seja atingida do
8  |   |   |   rnn.SimulatedAnnealing();
9  |   |   end
10 |   end
11 end
12 Dados novoPadrao
13 Classe classe = rnn.Classifica(novoPadrao);
14 return classe;
```

Capítulo 3

Reconhecimento de Gestos Dinâmicos Através da Abordagem Convexa

Os sistemas para reconhecimento de gestos normalmente são divididos em duas partes: a extração de características e a classificação dessas características. Sistemas baseados em visão computacional recebem dados a partir de câmeras de vídeo, e devem extrair características dessas imagens de forma que possam ser matematicamente representáveis. A partir dai, um módulo de classificação recebe as características e estima à qual classe ela pertence, normalmente utilizando uma base de dados previamente classificada.

O sistema descrito nesse trabalho não é diferente do sistema padrão, sendo composto pelas mesmas duas etapas, extração de características e classificação. Como se trata de um sistema para o reconhecimento de gestos dinâmicos, o sistema de extração recebe várias imagens capturadas por uma câmera de vídeo. Os *frames* capturados são enviados ao módulo de extração e as características descritas são enviadas ao módulo de classificação para então o gesto ser identificado. A Figura 3.1 exibe um fluxograma de funcionamento desse sistema.

O módulo de extração de características é responsável por receber os *frames* contendo as posturas da mão e gerar um arquivo de texto contendo os descritores das imagens. Agindo dessa forma, o módulo de extração pode conter vários tipos de técnicas de extração, o que permite que o sistema consiga ser adaptável ao tipo de gesto que se quer reconhecer. As imagens utilizadas como entrada devem ser as imagens recebidas pela câmera, de forma que o próprio método de extração seja responsável pelo seu pre-processamento e extração dos descritores. Os descritores são escritos em arquivos de texto, de forma que possam ser reaproveitados quando necessário.

O módulo de classificação utiliza os arquivos de texto criados pelo módulo de extração como forma de entrada. Esse módulo também pode implementar várias técnicas diferentes, de forma a ser adaptável ao problema em questão. As características podem ser enviadas em lote, ou por *frames* individuais, dependendo da técnica de classificação utilizada.

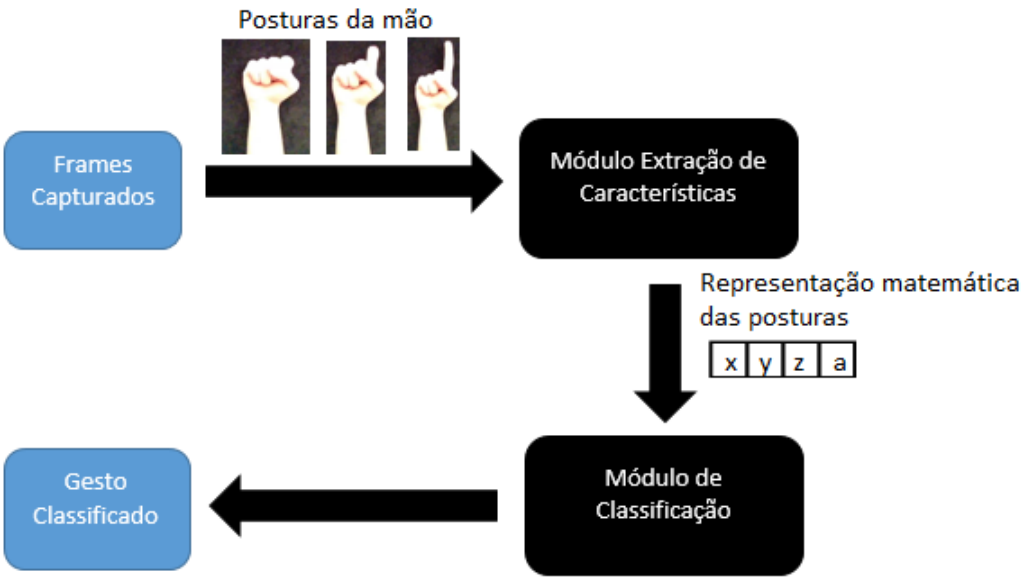

Figura 3.1: Arquitetura que descreve o sistema de reconhecimento de gestos proposto.

De forma a resolver o problema da extração de muitas características em um gesto dinâmico, uma nova técnica para extração de características é proposta. Essa técnica, denominada Abordagem Convexa, seleciona os pontos presentes no contorno da mão que melhor podem representa-la, sem a necessidade de utilizar o contorno completo.Essa técnica foi utilizada pela primeira vez no nosso trabalho [BJB+13] e descrita formalmente em nosso trabalho [**?**]. A sessão a seguir detalha o funcionamento da Abordagem Convexa.

3.1 Abordagem Convexa

Como visto no capítulo anterior, algumas técnicas de extração de características acabam representando um gesto com um vetor de tamanho elevado, o que pode acarretar em alguns problemas na hora da classificação, como exibido no capítulo 4. Para resolver tal problema, esse trabalho propõe uma técnica extração de características que seleciona a quantidade mínima de pontos para representar uma determinada postura de mão. Esse procedimento reduz a quantidade de informações necessárias para descrever aquela postura, aumentando a taxa de classificação correta dos gestos e diminuindo o tempo de processamento.

A Abordagem Convexa extrai as características de uma imagem por vez, sendo necessária que essa imagem contenha somente o contorno da mão. O primeiro passo do algoritmo é reduzir o modelo geométrico da mão, eliminando curvas. O segundo passo é encontrar os pontos que melhor podem descrever o modelo geométrico. O último passo é extrair a distância entre os pontos selecionados e compôr o vetor de características que descreverá a mão. A Figura 3.2 exibe um

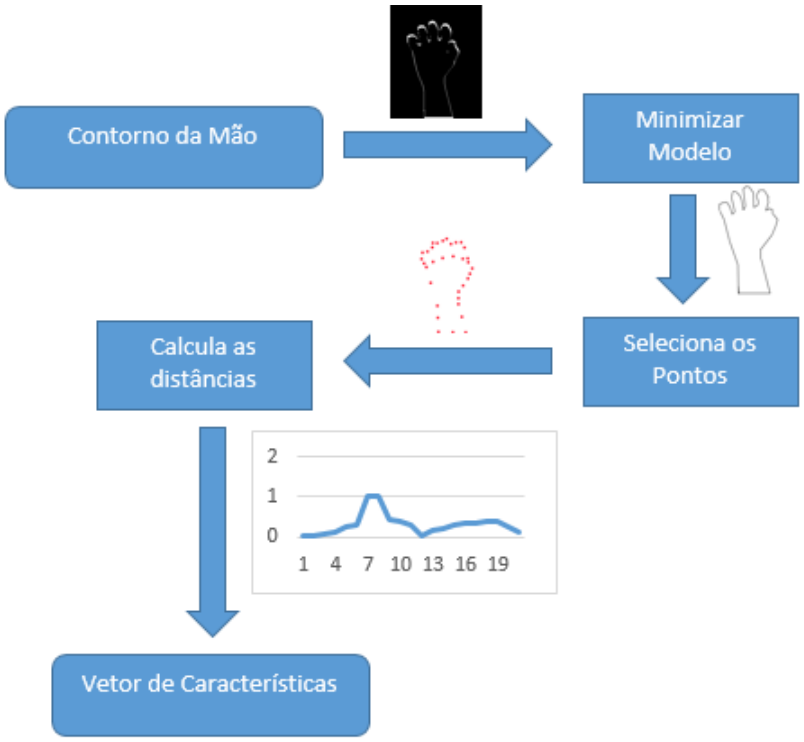

Figura 3.2: Fluxograma que descreve as etapas da Aproximação Convexa, método de extração de características para reconhecimento de gestos.

fluxograma de funcionamento da Abordagem Convexa.

3.1.1 Minimização do modelo geométrico

A primeira etapa do algoritmo garante que qualquer informação excedente seja extraída. No contexto de gestos realizados pelas mãos, entende-se como informação excedente aquela que é redundante ou que não possui um peso de significância baixo na hora da representação da mão. Um exemplo disso é uma curva qualquer, presente no contorno da mão, que pode ser facilmente representada por três pontos, um em cada extremidade e um no centro da parábola. Para criar um modelo minimizado da mão o algoritmo de simplificação poligonal Douglas-Peucker [DP73] é utilizado.

O Algoritmo de Douglas-Peucker é recursivo, e a cada passo processa o intervalo de pontos contidos entre um vértice inicial, denominado âncora, e um final, denominado flutuante. Na primeira execução do algoritmo os pontos mais distantes entre si do polígono são marcados como âncora e flutuante. Uma distância mínima, denominada tolerância T tem que ser previamente definida. Duas linhas paralelas são traçadas, contendo uma largura igual a $2T$, de forma que os pontos âncora e flutuante estejam no centro delas. A Figura 3.3(a) exibe o passo inicial do algoritmo Douglas-Peucker.

Caso todos os pontos do modelo processado estejam contidos dentro do corre-

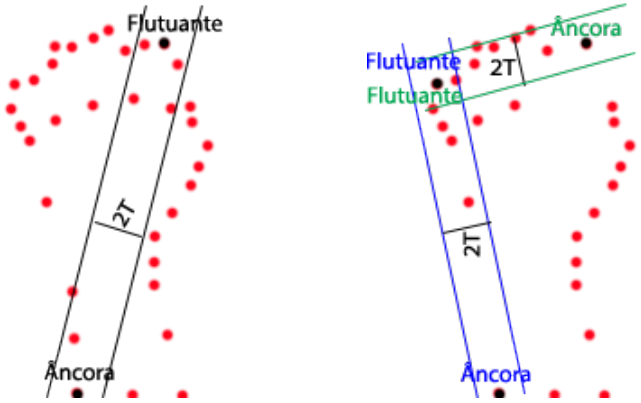

(a) Primeiro Passo (b) Segundo Passo

Figura 3.3: Passo inicial do algoritmo Douglas-Peucker, exibindo os pontos âncora e flutuante e o corredor com distância $2T$. Execução do algoritmo Douglas-Peucker. (a) exibe o primeiro passo, delimitando o corredor da distância $2T$. O segundo passo (b) seleciona o ponto mais distante do segmento de linha formados por âncora e flutuante e cria dois subgrupos, onde o algoritmo será executado novamente.

dor, isso quer dizer que a aproximação inicial formada pelo segmento de reta entre o ponto âncora e o flutuante é boa e todos os pontos são eliminados sobrando somente os pontos âncora e flutuante. Caso existam pontos fora do corredor, a distância entre esses pontos e o segmento de reta formado pelos pontos âncora e flutuante são calculadas. O ponto que obtiver a maior distância é selecionado e marcado como mais distante. O algoritmo agora divide o processamento em duas instâncias, uma onde o ponto inicial é o âncora anterior e o ponto flutuante é o ponto mais distante, e a outra onde o ponto âncora se torna o ponto mais distante e o ponto flutuante permanece. O processo é novamente executado, dessa vez em paralelo nessas duas instâncias. O algoritmo é executado até o fim, ou seja, até que todas as aproximações dos subconjuntos sejam consideradas aproximações boas. A Figura 3.3(a) exibe a continuação do processo iniciado na Figura 3.3(b), mostrando os subconjuntos selecionados.

Ao final da execução do algoritmo Douglas-Peucker, o polígono estará minimizado contendo somente os pontos que formarão os segmentos de reta do polígono minimizado. Um dos pontos importantes no algoritmo é a escolha da distância de tolerância T. Com uma distância muito grande, o algoritmo irá ignorar picos e depressões que podem ser importantes na descrição da mão, e uma distância muito pequena poderá pegar informações de mais, captando informações desnecessárias. A Figura 3.4 o resultado da aplicação do algoritmo de minimização de polígonos.

3.1.2 Extração dos pontos mais significativos

O segundo passo da Abordagem Convexa é a escolha dos pontos mais significativos no modelo minimizado. Para isso, a seleção dos pontos é realizada em dois mo-

(a) Imagem original

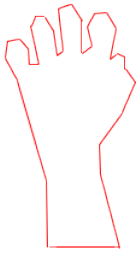

(b) Contorno da mão minimizado

Figura 3.4: Resultado da aplicação do algoritmo de minimização de polígonos Douglas-Peucker na imagem original (a). (b) exibe a saída do algoritmo, com o modelo minimizado, contendo menos curvas e mais vértices.

mentos: o primeiro é a seleção das arestas do polígonos que mais se destacam no modelo. O segundo é a escolha das arestas que mais detalham o modelo, baseadas nas arestas selecionadas anteriormente.

O primeiro momento é realizado através da execução de um fecho convexo ao redor do modelo. Ao se aproximar o fecho convexo do modelo, verifica-se quais vértices o tocam. Esses vértices são marcados, e todos os outros que não tocam o fecho, são eliminados. Um fecho convexo $F(x)$ d conjunto $x \subset \mathbb{R}^2$, $x = x_1, x2, x_3...xn$, é a menor região convexa de $\mathbb{R}^2$ que contém o conjunto x. O algoritmo de Sklansky [Skl82], corrigido posteriormente por [Mel87], consegue implementar um fecho convexo utilizando o processo descrito no Algoritmo 7.

O Algoritmo de Sklansky coloca três moedas em cima dos três primeiros vértices do polígono. As três moedas, são alteradas no decorrer do algoritmo, sempre avançando por vértices que foram uma curva à direita. Quando as três moedas realizam uma curva à esquerda, o vértice em que a primeira moeda se encontra deve ser retirado do modelo, volta-se um passo para trás e continua a busca. Isso ocorre até que todo o polígono possa ser representado por vértices que façam curva à direita, eliminando assim qualquer ponto não-convexo no polígono. A Figura 3.5(a) exibe o resultado da aplicação do algoritmo de Sklansky na imagem da Figura 3.4(b).

Após a execução do fecho convexo, os pontos que detalham o fecho convexo precisam ser encontrados. Como o fecho convexo encontra somente os pontos mais externos, delimitando à forma máxima da configuração da mão, alguns detalhes são perdidos, o que pode prejudicar a identificação do modelo da mão pelas técnicas de classificação. Esses detalhes são encontrados no segundo momento, onde os pontos internos são detalhados.

Para detalhar os pontos internos utiliza-se os pontos extraídos pelo fecho convexo e o modelo original com o contorno da mão. Para cada par de pontos extraídos pelo fecho convexo, uma reta é traçada. A distância entre todos os pontos contidos entre o par de pontos selecionados e a reta traçada é calculada, e o ponto que obtiver a maior distância é selecionado como ponto de detalhe. Caso não exista

Algorithm 7: Algoritmo para Extração dos pontos que tocam o fecho convexo de um polígono

```
1  Encontra-se o ponto mais externo do polígono, o com maior valor de
   coordenada y;
2  Ordena-se os pontos restantes em ordem horária, e nomeia-os começando
   por P_0;
3  Coloca-se três marcadores nos vértices P_0, P_1 e P_2, e nomeia-os como
   "Atrás", "Centro"e "Frente"respectivamente;
4  while Enquanto "Frente"não é o vértice P_0 e "Atrás", "Centro", e
   "Primeiro"fizerem uma curva para a direita do
5      if "Terceiro", "Segundo"e "Primeiro"formarem uma curva à direita ou
       forem vértices colineares then
6          Pega-se "Atrás"e o coloca no vértice subsequente à "Frente";
7          Coloca-sa "Atrás"no lugar de "Frente", "Frente"no lugar de
           "Centro"e "Centro"no lugar "Atrás";
8      end
9      else
10         Coloca-se "Centro"no vertice antes de "Atrás";
11         Remove o vértice em que "Centro"está;
12         Coloca-se "Centro"no lugar de "Atrás"e "Atrás"no lugar de
           "Centro";
13     end
14 end
15 Ordena-se os polígonos restantes em ordem horária.
```

nenhum ponto ou a distância seja igual a 0, nenhum ponto é considerado. A Figura 3.5(b) exibe a aplicação do realce dos pontos internos.

3.1.3 Composição do vetor de características

O último passo da Abordagem Convexa é a composição do vetor de características. Esse vetor é utilizado pelos classificadores para identificarem a postura de mão em um gesto, por isso precisam conter informações que descrevam com precisão a postura, sem conter informações redundantes ou irrelevantes. Para tanto um cálculo de distância nos pontos obtidos pelo passo anterior é executado.

A distância calculada entre os pontos permite que a Abordagem Convexa tenha as mesmas características do LCS, porém com menos pontos a serem considerados. A cada par de pontos externos extraídos no passo anterior, verifica-se se existe algum ponto interno entre eles. Caso exista, a distância entre uma reta traçada entre os pontos externos e o ponto interno é calculada e armazenada no vetor de características. Esse procedimento é realizado em todos os pontos, de forma que toda a configuração da mão seja representada. Isso garante que os pontos internos possam ser utilizados para detalhar os pontos externos, delimitando uma dependência na

(a) Primeiro Passo (b) Segundo Passo

Figura 3.5: A aplicação do algoritmo de Sklansky em um polígono minimizado de uma mão, gera uma imagem que enaltece os vértices externos(a). Já a aplicação do realce nos vértices internos, gera um modelo mais detalhado (b).

descrição do modelo da posição dos pontos internos e externos. Isso garante que pontos externos e internos, mesmo que sejam parecidos geometricamente, possam ser descritos de forma diferente no vetor de características.

Após a extração do vetor de características uma normalização de amplitude se vê necessária, de forma a transformar o algoritmo invariante à escala. Isso auxilia no processo de classificação, já que a mesma configuração de mão pode ser executada a distâncias diferentes da câmera, necessitando ser caracterizadas de forma igual. O processo de normalização de amplitude é simples, dividindo o valor de cada valor do distancia no vetor de características pelo desvio padrão. A Figura 3.6(a) exibe o vetor de características normalizado em amplitude extraído da postura da Figura 3.5(b).

Para algumas técnicas de classificação, como no caso das redes neurais, os vetores de características precisam estar normalizados em tamanho. Para resolver esse problema um algoritmo de normalização pode ser utilizado. Este trabalho propõe a utilização de um método para normalização baseado em amostragem. Primeiro o tamanho que se deseja normalizar é escolhido. Se o vetor de características possuir um tamanho menor do que o tamanho definido, valores 0 são adicionados ao final do vetor, ate que ele atinja o tamanho escolhido. Caso o vetor de características possua um tamanho maior,um algoritmo de seleção de amostras é utilizado. Esse algoritmo define uma janela w como o quociente da divisão do tamanho do vetor de características pelo tamanho desejado. O vetor de características então é visitado, e cada posição que seja múltiplo de w é adicionada em um novo vetor de saídas. Se o novo vetor de saídas ainda possuir um tamanho menor do que o desejado, as posições restantes, que não foram adicionadas no novo vetor, são visitadas aleatoriamente até que o tamanho desejado seja obtido.

Para exemplificar essa técnica de normalização, imagine que o vetor de características possua cem elementos. Deseja-se um vetor de características com onze

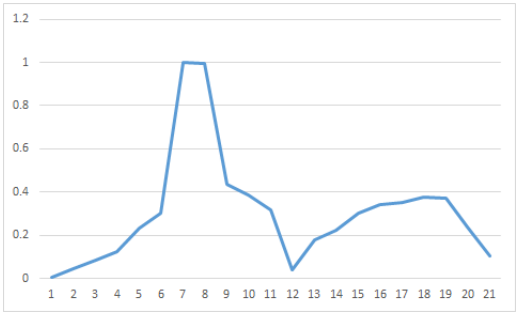

(a) Gesto extraído com a Abordagem Convexa

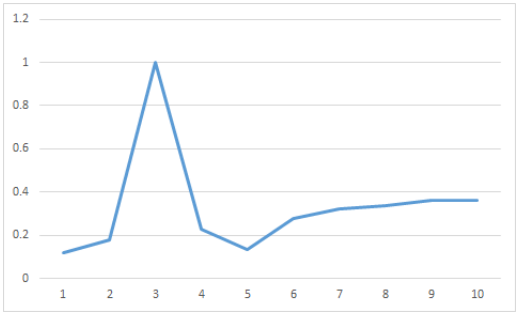

(b) Vetor normalizado

Figura 3.6: (a)Resultado da composição do vetor de características para a postura de mão exibida na Figura 3.5(b). Já (b) exibe o mesmo vetor de características normalizado com 10 elementos.

elementos. Como o vetor possui mais elementos do que o tamanho desejado, a janela w é calculada como $100/11 = 9$. Ao se visitar o vetor de características as posições 9, 18, 27, 36, 45, 54, 63, 72, 81 e 100 são adicionadas no novo vetor. Como o novo vetor so possui 10 elementos, uma posição é visitada aleatoriamente, excluindo-se as visitadas anteriormente, e é adicionada no novo vetor. A Figura 3.6(a) exibe o vetor da Figura 3.5(b) com aplicação da normalização de tamanho para 10 elementos.

3.1.4 Algoritmo da Abordagem Convexa

O algoritmo da Abordagem Convexa, Algoritmo 8, começa com a minimização do modelo, exibido na linha 1, utilizando o algoritmo de Douglas-Peucker. Com o modelo minimizado, a escolha dos pontos significantes é realizada, linha 2. Essa escolha separa os pontos em pontos externos, aqueles que definem o modelo, obtidos pelo algoritmo de Sklankys, e pontos internos, aqueles que detalham o modelo. O vetor de características é definido, adicionando-se sempre a distância entre um par de pontos externos e algum ponto interno que esteja entre eles, como exibido entre as linhas 3 e 6. Uma normalização de amplitude é necessária, linha 9, de forma que a classificação seja invariante à escala. Por último, se necessário, uma normalização de tamanho do vetor é realizada, utilizando um algoritmo baseado em escolha por amostragem, linha 10.

Algorithm 8: Algoritmo para Extração de características com a Abordagem Convexa

```
1  List<pontos> pontos = MinimizarModelo(Imagem);
2  pontos = ExtrairPontosSignificantes(pontos);
3  List<double> distancias;
4  for Par de pontos externos em pontos do
5  |  if Possui ponto interno then
6  |  |  distancias.add(pontosExternos,pontoInterno);
7  |  end
8  end
9  distancias = NormalizarAmplitude(distancias);
10 distancias = NormalizarTamanho(distancias,10);
11 return distancias
```

Capítulo 4

Metodologia e Experimentação

De modo a avaliar a técnica de extração de características proposta e a arquitetura implementada, uma série de testes são executados. Esses testes te como finalidade comparar a Abordagem Convexa com outras duas técnicas de extração, o *Local Contour Sequence* (LCS) e o *Speed Up Robust Features Extraction* (SURF). Três técnicas de classificação são implementadas no módulo de classificação: Uma Rede Neural de Elman (Elman RNN), um Modelo Oculto de Markov (HMM) e um *Dynamic Time Warping* (DTW).

Os testes são realizados com cada uma das técnicas de extração e classificação para gestos estáticos, dinâmicos e previsão de gestos. Uma base de gestos dinâmicos fo desenvolvida durante o trabalho da dissertação, e é utilizada durante todos os testes. As sessões a seguir descrevem a base de gestos dinâmicos e os testes, assim como os resultados dos experimentos.

4.1 Base de dados de gestos dinâmicos RPPDI

A base de gestos dinâmicos RPPDI[1] é composta por sete gestos realizados pela mão de um usuário. Várias sequências para cada gesto foram gravadas, de forma que existem vários exemplos de execução de cada gesto. A Figura 4.1 exibe exemplos dos gestos utilizados.

Nota-se que várias posturas se repetem em gestos diferentes, de forma que seja possível testar o reconhecimento e previsão de gestos dinâmicos, ou seja, através de posturas que variam com o tempo. Os sete gestos refletem várias posições de mãos diferentes, realizados de acordo com um fluxo de tempo. Uma pulseira de cor preta está presente no pulso para facilitar a separação entre mão e pulso, o que pode ajudar na execução de alguns algoritmos de extração de características. Cada gesto possui um total de 14 *frames*, e para cada gesto uma certa quantidade de exemplos foram gravadas. Cada exemplo reflete a execução do gesto de uma maneira diferente, simulando a variação na execução do gesto por pessoas diferentes. A Tabela 4.1 exibe a quantidade de sequências gravadas para cada gesto.

[1]Disponível em http://rppdi.ecomp.poli.br/gesture/database/

Figura 4.1: Ilustração dos sete gestos dinâmicos contidos na base de gestos dinâmicos RPPDI.

Tabela 4.1: Quantidade de sequências gravadas para cada gesto da base de gestos dinâmicos RPPDI

Gesto	Quantidade de sequências
Gesto 1	24
Gesto 2	24
Gesto 3	31
Gesto 4	18
Gesto 5	26
Gesto 6	33
Gesto 7	32

Todos os gestos foram gravados utilizando a mesma câmera, com $5mp$ de resolução. Depois de gravados, os gestos foram divididos em imagens, *frames*, e cada gesto é formado por 14 *frames* com um tamanho de $640x480$ *pixels*. Isso permite que a base de gestos possa ser utilizada tanto para o reconhecimento de gestos dinâmicos, onde todos os 14 *frames* são passados como uma sequência para os classificadores, como para a previsão de gestos, onde só o início de cada gesto é enviado para ser previsto. Isso também facilita nos testes para o reconhecimento de gestos estáticos, já que cada sequência de posições de mão pode ser separada em posições fixas a serem classificadas.

4.2 Metodologia Experimental

De forma a avaliar a eficiência e eficácia da técnica de extração de características proposta, uma série de testes utilizando a arquitetura proposta é realizada. Esses testes procuram comparar os resultados obtidos pela Abordagem Convexa com duas outras técnicas, o LCS e o SURF. Os testes são realizados em três diferentes experimentos: reconhecimento de gestos estáticos, reconhecimento de gestos dinâmicos e previsão de gestos.

A Abordagem Convexa utiliza o contorno da mão para extrair as informações que melhor descrevem a postura. De forma a obter resultados mais consistentes, a extração do contorno para a Abordagem Convexa é realizada de duas maneiras diferentes: a primeira utilizando uma série de técnicas de processamento de imagens, as mesmas utilizadas para gerar o LCS, compostas por segmentação da imagem e encontrar o contorno. A segunda utiliza os pontos de interesse extraídos pelo SURF, formando um contorno da postura da mão com esses pontos. A aplicação da Abordagem Convexa nessas duas técnicas é denominada, respectivamente de CLCS e CSURF.

Os testes são realizados utilizando a arquitetura proposta. O módulo de extração de características é implementado com quatro diferentes técnicas, o LCS, o SURF, o CLCS e o CSURF. As características extraídas por cada técnica são encaminhadas para o módulo de classificação, que implementa três técnicas de classificação diferentes: HMM, DTW e Elman RNN.

4.2.1 Experimento 1: Reconhecimento de gestos estáticos

O primeiro experimento, denominado Reconhecimento de gestos estáticos, tem como função a comparação de taxa de classificação corretas, tempo de execução e tempo de treino para cada par de algoritmos testados(técnica e extração e técnica de classificação). O experimento utiliza posturas de mão extraídas da base de gestos dinâmicos RPPDI e separa-as em oito classes. A Figura 4.2 exibe as oito posturas a serem reconhecidas. A Tabela 4.2 exibe a quantidade de exemplos para cada postura.

Devido ao caráter estático desse experimento, visto que não existe evolução em uma linha de tempo nos gestos executados, a técnica de classificação HMM

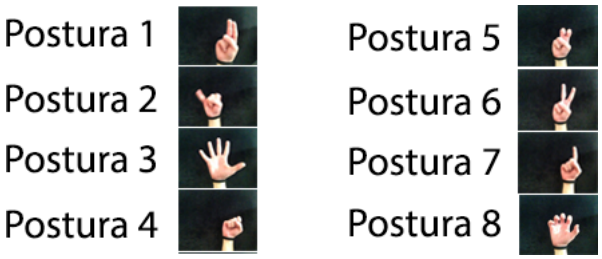

Figura 4.2: Ilustração dos sete gestos dinâmicos contidos na base de gestos dinâmicos RPPDI.

Tabela 4.2: Quantidade de sequências presentes para cada classe de posturas no experimento Reconhecimento de gestos estáticos.

Postura	Quantidade de sequências
Postura 1	24
Postura 2	24
Postura 3	31
Postura 4	18
Postura 5	26
Postura 6	33
Postura 7	32
Postura 8	32

não é utilizada. O mesmo ocorre com a Elman RNN, que apresenta resultados melhores em padrões que evoluem com o tempo. Retirando a camada de recursão da Elman RNN ela se torna uma *Multilayer Perceptron*(MLP) , que será utilizada nesse experimento. Nesse experimento a o algoritmo utilizado para treinamento da MLP é o *Backpropagation*.

Os testes ocorrem em três diferentes divisões das sequências de posturas: 1/3 das sequências para treinamento e 2/3 para a validação, 1/2 para o treinamento e 1/2 para a validação e 2/3 para o treinamento e 1/3 para a validação. Cada teste é executado trinta vezes, e os resultados exibem a média dessas execuções. A configuração dos parâmetros para cada algoritmo foi escolhida de forma empírica, utilizando-se aproximação por tentativa e erro. A Tabela 4.3 exibe a melhor configuração para as técnicas de classificação.

Tabela 4.3: Configurações utilizadas para cada par de algorítmos

Technique	Parameters	CLCS	CSURF	LCS	SURF
MLP	Neurons Input Layer	140	210	5600	1400
	Hidden Layers	12	14	75	37
	Neurons Output Layer	4	4	4	4
DTW	Features	140	210	5600	1400

Tabela 4.4: Configuração de cada par de técnica de extração e classificação

Técnica	Parâmetros	CLCS	CSURF	LCS	SURF
Elman RNN	Neurônios camada entrada	140	210	5600	1400
	Camadas Escondidas	12	14	75	37
	Neurônios camada de saída	4	4	4	4
HMM	Estados	3	3	3	3
	Iterações Baum-Welch	100	100	10	10
	Características	10	10	5600	1400
DTW	Características	140	210	5600	1400

4.2.2 Experimento 2: Reconhecimento de gestos dinâmicos

O segundo experimento, denominado Reconhecimento de gestos dinâmicos, tem a função de testar a Abordagem Convexa e a arquitetura proposta com gestos dinâmicos. Todos os sete gestos presentes na base de gestos dinâmicos RPPDI são utilizados nesse experimento.

As técnicas de extração de características utilizadas nesse experimento são: LCS, SURF, CLCS e CSURF. Para o módulo de classificação, as técnicas implementadas são: Elman RNN, HMM e DTW.

As técnicas de extração são aplicadas em todos os *frames* de cada gesto, no módulo de extração, que são passados em lote, ou seja, todas as características extraídas dos 14 *frames*, para módulo de classificação.

Cada vetor de características, representando um *frame*, é passado na Elman RNN individualmente. A cada 14 *frames* passados, a rede apresenta uma classificação. O treinamento dessa rede se dá através do *Backpropagation* combinado com o *Simulated Annealing*, e ocorre utilizando uma janela de 14 *frames*.

Cada gesto presente na base de gestos é representado por um HMM diferente. Para se classificar um novo gesto, todos os 14 vetores de características são apresentados à cada HMM. O gesto representado pelo HMM que gerar a maior probabilidade de saída, dado o vetor de características apresentado, é escolhido como o gesto classificado.

No DTW separa-se cada conjunto vetor de característica que representa os gestos em grupos, cada grupo representando um gesto. Um novo gesto é classificado comparando-o com todos os elementos de cada grupo, o grupo que obtiver a menor média de distâncias é escolhido como o gesto classificado.

Os testes ocorrem em três diferentes divisões das sequências de posturas: 1/3 das sequências para treinamento e 2/3 para a validação, 1/2 para o treinamento e 1/2 para a validação e 2/3 para o treinamento e 1/3 para a validação. Cada teste é executado trinta vezes, e os resultados exibem a média dessas execuções. A configuração dos parâmetros para cada algoritmo foi escolhida de forma empírica, utilizando-se aproximação por tentativa e erro. A Tabela 4.4 exibe a melhor configuração para as técnicas de classificação, bem como a quantidade de características extraídas para cada sequência de gestos.

Tabela 4.5: Resultados obtidos para o reconhecimento de gestos estáticos utilizando o LCS no módulo de extração e o DTW no módulo de classificação

Divisão Dados	Class. Correta(%)	Desv. pad.	Tempo treino(ms)	Tempo class.(ms)
$\frac{1}{3}$ Treino	70,03	2,32	11,02	2,69
$\frac{1}{2}$ Treino	73,02	3,00	11,00	3,82
$\frac{2}{3}$ Treino	78,52	1,70	11,61	3,62

4.2.3 Experimento 3: Previsão de gestos dinâmicos

No último experimento, a capacidade da arquitetura de prever gestos é avaliada. A previsão de gestos é definida como um reconhecimento de gestos incompletos, que pode ajudar no reconhecimento de gestos em tempo real.

Para esse experimento, as quatro técnicas de extração de características são aplicadas no módulo de extração: CLCS, CSURF, LCS e HMM. Para o módulo de classificação, são utilizadas: DTW e HMM. A Elman RNN não foi documentada nesse experimento pois os resultados apresentados não foram suficientes para a previsão dos gestos. Os testes foram executados somente com a divisão de $\frac{2}{3}$ dos dados para treino, pois o objetivo do teste é a comparação entre as técnicas na tarefa de previsão de gesto.

O processo de previsão se da quando um gesto incompleto é classificado pelo módulo de classificação. Para tanto, as técnicas de classificação são treinadas utilizando-se todo a base de gestos dinâmicos. A diferença se da na hora da classificação, onde, para cada teste, são passados gestos incompletos, ou seja, com menos *frames* do que um gesto completo. Os testes foram executados com a mesma configuração do experimento anterior, porém, são executados para intervalos de *frames*. Cada teste é iniciado apenas com 1 *frame*, o *frame* inicial, e a cada iteração um novo *frame* é adicionado ao intervalo, ate que todos os 14 *frames* sejam adicionados.

4.3 Resultados e Discussões

4.3.1 Experimento 1: Reconhecimento de gestos estáticos

Utilizando a combinação de LCS no módulo de extração e DTW no módulo de classificação, a melhor taxa obtida foi de $78,52\%$, com uma divisao de $\frac{2}{3}$ da base de gestos para treino. Com uma divisão de $\frac{1}{2}$, a taxa ficou em $73,02\%$. Já com uma divisão de $\frac{1}{3}$ dos dados para treino, a taxa obtida foi de $70,03\%$. A Tabela 4.5 exibe o resultado encontrado.

A combinação SURF, no módulo de extração, e DTW no módulo de classificação obteve um resultado de $70,72\%$ para uma divisão de $\frac{2}{3}$ dos dados para treino. Uma divisão de $\frac{1}{2}$ obteve um total de $63,01\%$ e uma divisão de $\frac{1}{3}$ obteve um resultado de $57,16\%$ dos gestos classificados corretamente. A Tabela 4.6 exibe o resultado encontrado.

Tabela 4.6: Resultados obtidos para o reconhecimento de gestos estáticos utilizando o SURF no módulo de extração e o DTW no módulo de classificação

Divisão Dados	Class. Correta(%)	Desv. pad.	Tempo treino(ms)	Tempo class.(ms)
$\frac{1}{3}$ Treino	57,16	2,32	120,42	52,00
$\frac{1}{2}$ Treino	63,01	4,08	130,40	53,38
$\frac{2}{3}$ Treino	70,72	7,10	190,43	50,56

Tabela 4.7: Resultados obtidos para o reconhecimento de gestos estáticos utilizando o CSURF no módulo de extração e o DTW no módulo de classificação

Divisão Dados	Class. Correta(%)	Desv. pad.	Tempo treino(ms)	Tempo class.(ms)
$\frac{1}{3}$ Treino	73,32	1,82	4,09	1,09
$\frac{1}{2}$ Treino	78,46	6,08	4,21	0,99
$\frac{2}{3}$ Treino	82,53	4,01	6,33	1,23

Utilizando o CSURF no módulo de extração e o DTW no módulo de classificação, o sistema conseguiu uma taxa de $82,53\%$ de reconhecimento correto, para uma divisão de $\frac{2}{3}$ dos dados para treinamento. Já com uma divisão de $\frac{1}{2}$, o resultado obtido foi de $78,46\%$. Uma divisão de $\frac{1}{3}$ dos dados para treino obteve um resultado de $73,32\%$ dos gestos reconhecidos corretamente. A Tabela 4.7 exibe o resultado encontrado.

A combinação CLCS, no módulo de extração, e DTW, no módulo de classificação, foi capaz de obter um resultado de $87,52\%$ de gestos reconhecidos corretamente, à uma divisão de $\frac{2}{3}$ dos dados para treino. Já uma à uma divisão de $\frac{1}{2}$ da base para treino, o resultado obtido foi de $83,01\%$. Uma divisão de $\frac{1}{3}$ conseguiu uma taxa de gestos reconhecidos corretamente de $78,00\%$. A Tabela 4.8 exibe o resultado encontrado.

Combinando o LCS, no módulo de extração, com a MLP, no módulo de classificação resultou em uma taxa de reconhecimento de $73,52\%$ para uma divisão de $\frac{2}{3}$ dos dados para treino. Já uma divisão de $\frac{1}{2}$ obteve um total de $65,02\%$ de gestos reconhecidos. Uma divisão de $\frac{1}{2}$, obteve um total de $62,03\%$ de dados reconhecidos corretamente. A Tabela 4.9 exibe o resultado encontrado.

utilizando uma MLP no módulo de classificação, em combinação com o SURF no módulo de extração, conseguiu atingir uma taxa de $67,87\%$ de reconhecimentos corretos, para uma divisão de $\frac{2}{3}$ dos dados para treino. Já dividindo os dados em $\frac{1}{2}$ para treino e $\frac{1}{2}$ para teste, obteve-se um resultado de $60,19\%$. Já a divisão $\frac{1}{3}$,

Tabela 4.8: Resultados obtidos para o reconhecimento de gestos estáticos utilizando o CLCS no módulo de extração e o DTW no módulo de classificação

Divisão Dados	Class. Correta(%)	Desv. pad.	Tempo treino(ms)	Tempo class.(ms)
$\frac{1}{3}$ Treino	78,00	3,09	4,98	0,98
$\frac{1}{2}$ Treino	83,01	2,07	5,37	0,92
$\frac{2}{3}$ Treino	87,52	3,56	6,00	0,97

Tabela 4.9: Resultados obtidos para o reconhecimento de gestos estáticos utilizando o LCS no módulo de extração e a MLP no módulo de classificação

Divisão Dados	Class. Correta(%)	Desv. pad.	Tempo treino(ms)	Tempo class.(ms)
$\frac{1}{3}$ Treino	62,03	2,33	20110,11	1,15
$\frac{1}{2}$ Treino	65,02	1,98	20545,32	1,00
$\frac{2}{3}$ Treino	73,52	1,24	20910,45	1,11

Tabela 4.10: Resultados obtidos para o reconhecimento de gestos estáticos utilizando o SURF no módulo de extração e o MLP no módulo de classificação

Divisão Dados	Class. Correta(%)	Desv. pad.	Tempo treino(ms)	Tempo class.(ms)
$\frac{1}{3}$ Treino	55,12	4,97	23072,42	1,67
$\frac{1}{2}$ Treino	60,19	2,58	25398,40	1,43
$\frac{2}{3}$ Treino	67,87	3,12	29053,45	1,56

obteve um resultado de $55,12\%$ de gestos reconhecidos corretamente. A Tabela 4.10 exibe o resultado encontrado.

A utilização da combinação CSURF, no módulo de extração, e MLP no módulo de classificação conseguiu obter um resultado de $79,34\%$ de reconhecimento para uma divisão de $\frac{2}{3}$ da base para treino. Já para uma divisão de $\frac{1}{2}$ da base para treino, um total de $73,09\%$ dos gestos foram reconhecidos corretamente. Para uma divisão de $\frac{1}{3}$, uma taxa de $69,81\%$ foi obtida. A Tabela 4.11 exibe o resultado encontrado.

Utilizando o CLCS no módulo de extração e a MLP no módulo de classificação e uma divisão de $\frac{2}{3}$ da base para treino, a taxa de gestos corretamente classificados ficou em $80,65\%$. Já utilizando uma divisão de $\frac{1}{2}$, obteve uma taxa de $74,03\%$. Uma divisão de $\frac{1}{3}$, conseguiu obter uma taxa de $70,09\%$. A Tabela 4.12 exibe o resultado encontrado.

A utilização da Abordagem Convexa nas técnicas LCS e SURF produziram resultados com taxas de reconhecimento de gestos corretos maiores, bem como diminuiu o tempo de classificação e treinamento das técnicas de classificação testadas.

Tabela 4.11: Resultados obtidos para o reconhecimento de gestos estáticos utilizando o CSURF no módulo de extração e o MLP no módulo de classificação

Divisão Dados	Class. Correta(%)	Desv. pad.	Tempo treino(ms)	Tempo class.(ms)
$\frac{1}{3}$ Treino	69,81	5,87	13009,43	0,79
$\frac{1}{2}$ Treino	73,09	4,12	16523,12	0,70
$\frac{2}{3}$ Treino	79,34	3,91	15053,98	0,85

Tabela 4.12: Resultados obtidos para o reconhecimento de gestos estáticos utilizando o CLCS no módulo de extração e o MLP no módulo de classificação

Divisão Dados	Class. Correta(%)	Desv. pad.	Tempo treino(ms)	Tempo class.(ms)
$\frac{1}{3}$ Treino	70,09	3,09	10911,11	0,78
$\frac{1}{2}$ Treino	74,03	2,07	12032,61	0,87
$\frac{2}{3}$ Treino	80,65	3,56	13552,87	0,83

Tabela 4.13: Resultados obtidos para o reconhecimento de gestos dinâmicos utilizando o LCS no módulo de extração e o HMM no módulo de classificação

Divisão Dados	Class. Correta(%)	Desv. pad.	Tempo treino(ms)	Tempo class.(ms)
$\frac{1}{3}$ Treino	27,48	7.55	496.52	3.07
$\frac{1}{2}$ Treino	39,29	6.33	636.07	3.11
$\frac{2}{3}$ Treino	52,55	5,70	772.41	3.07

4.3.2 Experimento 2: Reconhecimento de gestos dinâmicos

Utilizando a combinação do LCS, no módulo de extração, e o HMM, no módulo de classificação, a melhor a taxa de gestos corretamente reconhecidos foi de $52,55$ %. Essa taxa foi obtida utilizando a divisão de $\frac{2}{3}$ da base de gestos para treino e $\frac{1}{3}$ para teste. Com uma divisão de $\frac{1}{3}$ dos dados para treino, o resultado obtido foi de $27,48\%$ dos gestos reconhecidos corretamente e para a divisão $\frac{1}{2}$ dos dados para treino a taxa foi de $39,29\%$. Observa-se também que o tempo de classificação médio é praticamente o mesmo para todas as divisões, o que não acontece com o tempo de treino, que aumenta de acordo com o tamanho da base de treino. A tabela 4.13 exibe o resultado obtido por cada divisão, bem como o desvio padrão e o tempo médio para treino e classificação de cada padrão.

Utilizando a combinação entre SURF, no módulo de extração, e HMM no módulo de classificação, os resultados obtidos foram insuficientes para o reconhecimento. Como a quantidade de características extraídas pelo SURF para cada gesto é muito alta, 1400 características, como exibido na Tabela 4.4, e cada característica do SURF ser composta por 64 dimensões, o HMM não consegue convergir em nenhuma divisão da base de treino. A Tabela 4.14 descreve o resultado obtido.

A combinação entre o CLCS, no módulo de extração, e o HMM , no módulo de classificação, mostra resultados superiores, chegando a uma taxa de acerto de $81,66\%$ para a divisão de base de dados em $\frac{2}{3}$ para treino e $\frac{1}{3}$ para teste. Já com

Tabela 4.14: Resultados obtidos para o reconhecimento de gestos dinâmicos utilizando o SURF no módulo de extração e o HMM no módulo de classificação

Divisão Dados	Class. Correta(%)	Desv. pad.	Tempo treino(ms)	Tempo class.(ms)
$\frac{1}{3}$ Treino	12,59	0,0	1221.13	7,58
$\frac{1}{2}$ Treino	12,63	0,0	1601.37	7,79
$\frac{2}{3}$ Treino	12,50	0,0	1902.83	7,77

Tabela 4.15: Resultados obtidos para o reconhecimento de gestos dinâmicos utilizando o CLCS no módulo de extração e o HMM no módulo de classificação

Divisão Dados	Class. Correta(%)	Desv. pad.	Tempo treino(ms)	Tempo class.(ms)
$\frac{1}{3}$ Treino	68,13	4,87	124,15	0,769
$\frac{1}{2}$ Treino	76,70	5,24	159,06	0,77
$\frac{2}{3}$ Treino	81,66	5,41	193,99	0,79

Tabela 4.16: Resultados obtidos para o reconhecimento de gestos dinâmicos utilizando o CSURF no módulo de extração e o HMM no módulo de classificação

Divisão Dados	Class. Correta(%)	Desv. pad.	Tempo treino(ms)	Tempo class.(ms)
$\frac{1}{3}$ Treino	54,40	5,05	192,08	1,19
$\frac{1}{2}$ Treino	69,89	4,50	243,72	1,17
$\frac{2}{3}$ Treino	77,44	4,81	299,65	1,19

a divisão $\frac{1}{2}$ para treino e $\frac{1}{2}$ para teste, a taxa atingida foi de $76,70\%$. Utilizando a divisão $\frac{1}{3}$ da base de gestos para treino e $\frac{2}{3}$ para teste, a taxa encontrada foi de $68,13$ %. Observa-se uma evolução quando da aplicação da Abordagem Convexa no contorno extraído pelo LCS, quando comparado ao resultado obtido pelo LCS. Essa evolução se da na taxa de classificação e também no tempo de classificação de cada padrão, que diminui bastante. A Tabela 4.15 descreve esses resultados.

A utilização da Abordagem Convexa utilizando os pontos extraídos pelo SURF como contorno, denominada CSURF, obteve resultados parecidos com os resultados do CLCS. Uma taxa de acerto de $77,44\%$ foi obtida para a divisão de base de dados em $\frac{2}{3}$ para treino e $\frac{1}{3}$ para teste. Já com a divisão $\frac{1}{2}$ para treino e $\frac{1}{2}$ para teste, a taxa atingida foi de $69,89\%$. Utilizando a divisão $\frac{1}{3}$ da base de gestos para treino e $\frac{2}{3}$ para teste, a taxa encontrada foi de $54,40$ %. A Tabela 4.16 descreve esses resultados.

Utilizando o LCS no módulo de extração e o DTW no módulo de classificação, os resultados obtidos foram melhores do que os obtidos quando utilizado o HMM no módulo de classificação. Para uma divisão de $\frac{2}{3}$ da base de dados para treino, um resultado de $89,06$ % de gestos reconhecidos corretamente foi obtido. Já com uma divisão de $\frac{1}{2}$ da base de dados para treino, um resultado de $83,59$ % foi obtido e com uma divisão de $\frac{1}{3}$ da base de dados para treino, um resultado de $79,47$ % foi obtido. A Tabela 4.17 descreve o resultado.

O SURF, como método de extração de características, obteve resultados baixos,

Tabela 4.17: Resultados obtidos para o reconhecimento de gestos dinâmicos utilizando o LCS no módulo de extração e o DTW no módulo de classificação

Divisão Dados	Class. Correta(%)	Desv. pad.	Tempo treino(ms)	Tempo class.(ms)
$\frac{1}{3}$ Treino	79,47	4,19	2820,32	792,33
$\frac{1}{2}$ Treino	83,59	4,89	2840,91	1003,49
$\frac{2}{3}$ Treino	89,06	4,88	2880,04	1237,47

Tabela 4.18: Resultados obtidos para o reconhecimento de gestos dinâmicos utilizando o SURF no módulo de extração e o DTW no módulo de classificação

Divisão Dados	Class. Correta(%)	Desv. pad.	Tempo treino(ms)	Tempo class.(ms)
$\frac{1}{3}$ Treino	12,5	1,0	3590,05	1589,02
$\frac{1}{2}$ Treino	25,3	1,5	3750,35	1370,07
$\frac{2}{3}$ Treino	37,2	2,87	3710,079	1799,58

Tabela 4.19: Resultados obtidos para o reconhecimento de gestos dinâmicos utilizando o CSURF no módulo de extração e o DTW no módulo de classificação

Divisão Dados	Class. Correta(%)	Desv. pad.	Tempo treino(ms)	Tempo class.(ms)
$\frac{1}{3}$ Treino	85,30	4,10	252,61	75,19
$\frac{1}{2}$ Treino	87,99	3,63	250,53	73,25
$\frac{2}{3}$ Treino	94,08	3,20	257,09	79,75

devido à quantidade de características extraídas para o reconhecimento de gestos dinâmicos. Utilizando o DTW no módulo de classificação, o resultado não foi diferente. Utilizando uma divisão da base de dados de $\frac{1}{3}$ para treino, o DTW não conseguiu generalizar um reconhecimento, e a taxa foi de apenas $12,5\%$. Já para uma divisão de $\frac{1}{2}$, o resultado sobe um pouco, para $25,3\%$. Para uma divisão de $\frac{2}{3}$ para a base de treino, o resultado foi de $37,2\%$. A Tabela 4.18 descreve os resultados encontrados.

Utilizando a Abordagem Convexa aplicada aos pontos interesse do SURF, o CSURF, no módulo de extração e o DTW no módulo de classificação, os resultados obtidos foram melhores do que utilizando os descritores do SURF. Para uma divisão de $\frac{2}{3}$ da base de dados para treino, um resultado de $85,30$ % de gestos reconhecidos corretamente foi obtido. Já com uma divisão de $\frac{1}{2}$ da base de dados para treino, um resultado de $87,99$ % foi obtido e com uma divisão de $\frac{1}{3}$ da base de dados para treino, um resultado de $94,08$ % foi obtido. A Tabela 4.19 descreve o resultado.

As mais altas taxas de classificação corretas foram encontradas utilizando o CLCS no módulo de extração e o DTW no módulo de classificação. Para uma divisão de $\frac{1}{3}$ da base de dados para treino, um resultado de $93,70\%$ foi obtido. Para uma divisão de $\frac{1}{2}$, um resultado de $95,60\%$ foi obtido e para uma divisão de $\frac{2}{3}$, um resultado de $97,00\%$ de reconhecimento correto foi encontrado. A Tabela 4.20 detalha os resultados obtidos.

Tabela 4.20: Resultados obtidos para o reconhecimento de gestos dinâmicos utilizando o CLCS no módulo de extração e o DTW no módulo de classificação

Divisão Dados	Class. Correta(%)	Desv. pad.	Tempo treino(ms)	Tempo class.(ms)
$\frac{1}{3}$ Treino	93,70	1,47	243,78	65,13
$\frac{1}{2}$ Treino	95,60	2,70	246,90	62,97
$\frac{2}{3}$ Treino	97,00	2,70	244,85	63,37

Tabela 4.21: Resultados obtidos para o reconhecimento de gestos dinâmicos utilizando o LCS no módulo de extração e o Elman RNN no módulo de classificação

Divisão Dados	Class. Correta(%)	Desv. pad.	Tempo treino(ms)	Tempo class.(ms)
$\frac{1}{3}$ Treino	51,0	5,32	189872,89	1,41
$\frac{1}{2}$ Treino	57,51	6,12	201212,12	1,00
$\frac{2}{3}$ Treino	63,32	2,32	262121,33	1,23

Tabela 4.22: Resultados obtidos para o reconhecimento de gestos dinâmicos utilizando o SURF no módulo de extração e o Elman RNN no módulo de classificação

Divisão Dados	Class. Correta(%)	Desv. pad.	Tempo treino(ms)	Tempo class.(ms)
$\frac{1}{3}$ Treino	17,18	2,36	439144,43	1,44
$\frac{1}{2}$ Treino	27,98	1,09	471212,12	1,43
$\frac{2}{3}$ Treino	36,45	4,21	502122,92	1,37

Utilizando o LCS, no módulo de extração, e a Elman RNN no módulo de classificação, um resultado de $51,0\%$ de gestos reconhecidos corretamente foi obtido, utilizando uma taxa de $\frac{1}{3}$ dos dados para treino. Já para uma divisão de $\frac{1}{2}$ para treino, o resultado obtido foi de $57,51\%$ de gestos corretos. Utlizando uma taxa de $\frac{2}{3}$ dos gestos para o treino, foi possível obter um resultado de $63,32\%$ de gestos reconhecidos corretamente. A Tabela 4.21 detalha os resultados obtidos.

Com a técnica SURF no módulo de extração e a Elman RNN no módulo de classificação, os resultados continuaram baixos, como ocorreu com o uso do DTW e do HMM. Para uma divisão de $\frac{1}{3}$ dos dados para treino, a taxa de gestos classificados corretamente foi de $17,18\%$. Já para uma divisao de $\frac{1}{2}$, o resultado obtido foi de $27,98\%$. Para uma divisao de $\frac{2}{3}$ dos dados para treino, o resultado obtido foi de $36,45\%$ dos gestos reconhecidos corretamente. A Tabela 4.22 detalha os resultados obtidos.

Com o uso da técnica CSURF no módulo de extração e a Elman RNN no módulo de classificação os resultados obtidos conseguiram atingir uma taxa de $76,53\%$ de gestos reconhecidos corretamente para uma uma divisão de $\frac{2}{3}$ dos dados para treino. Já para uma divisão de $\frac{1}{2}$, o resultado obtido foi de $71,05\%$. Para uma divisão de $\frac{2}{3}$, o resultado obtido foi de $63,91\%$. A Tabela 4.23 detalha os resultados obtidos.

Já utilizando o CLCS no módulo de extração, e a Elman RNN no módulo de classificação, o melhor resultado obtido foi de $80,00\%$ dos gestos reconhecidos

Tabela 4.23: Resultados obtidos para o reconhecimento de gestos dinâmicos utilizando o CSURF no módulo de extração e o Elman RNN no módulo de classificação

Divisão Dados	Class. Correta(%)	Desv. pad.	Tempo treino(ms)	Tempo class.(ms)
$\frac{1}{3}$ Treino	63,91	2,38	12921,32	1,21
$\frac{1}{2}$ Treino	71,05	1,59	15923,23	1,00
$\frac{2}{3}$ Treino	76,53	1,33	17233,73	0,91

Tabela 4.24: Resultados obtidos para o reconhecimento de gestos dinâmicos utilizando o CLCS no módulo de extração e o Elman RNN no módulo de classificação

Divisão Dados	Class. Correta(%)	Desv. pad.	Tempo treino(ms)	Tempo class.(ms)
$\frac{1}{3}$ Treino	69,98	1,24	10854.31	0,99
$\frac{1}{2}$ Treino	75,12	5,79	16847,82	1,23
$\frac{2}{3}$ Treino	80,00	2,79	18592,16	0,92

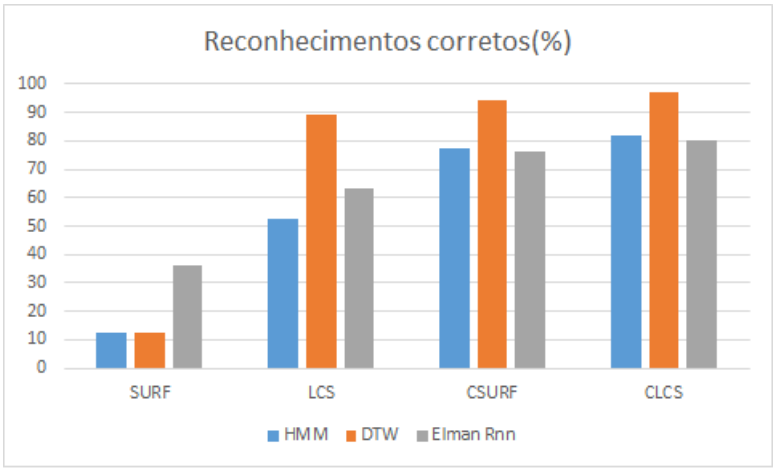

Figura 4.3: Gráfico exibindo os resultados de classificação para todas as técnicas testadas.

corretamente, a uma divisão de $\frac{2}{3}$ dos dados para o treino. Já com uma divisão de $\frac{1}{2}$ dos dados para treino, o resultado obtido foi de $75,12\%$. E para uma divisão de $\frac{1}{3}$, a taxa obtida foi de $69,98\%$. A Tabela 4.24 detalha os resultados obtidos.

Como visto nos resultados obtidos, a aplicação da Abordagem Convexa nas técnicas LCS e SURF, formando o CLCS e CSURF respectivamente, demonstram uma taxa de classificação maior, bem como tempos de treino e classificação de cada padrão menores. Esse resultado comprova que a redução do vetor de características, proposto pelo algoritmo da Abordagem Convexa é eficaz e eficiente, no domínio aplicado.

Para a classificação, todos os resultados obtidos com o CLCS e o CSURF foram maiores que os obtidos pelo LCS e o SURF. A Figura 4.3 exibe um resumo das classificações obtidas. Isso acontece pelo fato das técnicas com a Abordagem Convexa possuírem menos características, já que a aplicação do algoritmo seleciona somente as distâncias que influenciam na representação da forma da mão. A taxa obtida pelo SURF se mostrou demasiadamente pequena em todas as técnicas de classificação, fato este comprovado pela quantidade elevada de características extraídas de cada *frame* que compõe um gesto. O CLCS foi a técnica que obteve maiores resultados, em todas as técnicas. De todas as combinações, àquelas realizadas com o DTW obtiveram as melhores taxas. Isso ocorre, devido à capacidade do DTW comparar sequências distintas em tamanho e em velocidade, o que o torna uma poderosa técnica de comparação para gestos dinâmicos.

Tabela 4.25: Resultado da previsão adicionando-se os quatro primeiro *frames* no vetor de características para o CLCS.

Técnica Classificação	Resultado	F1	F2	F3	F4
HMM	Taxa predição(%)	37,9	43.6	49,9	54,4
HMM	Desvio padrão	6,5	5,6	4,1	5,3
HMM	Tempo de predição(ms)	0,10	0,17	0,26	0,34
DTW	Taxa predição(ms)(%)	17,18	17,42	17,06	17,34
DTW	Desvio padrão	0,0	0,27	0,70	0,47
DTW	Tempo de predição(ms)	9,7	9,5	29,0	40,1

Levando em consideração o tempo de classificação de um padrão e de treinamento, o HMM é a técnica que possui melhores resultados. A Figura 4.4(a) exibe um gráfico mostrando a comparação entre os tempos para treinamento de todas as combinações. Já a Figura 4.4(b) exibe o gráfico comparando o tempo de classificação de um gesto para todas as combinações de técnicas. Os gráficos exibidos na Figura 4.4 estão em escala logarítmica de 10 de forma a melhorar a percepção das diferenças entre os valores. O DTW, apesar de obter uma taxa de classificação melhor, apresenta tempos elevados para a classificação dos gestos. Isso ocorre pelo motivo do DTW calcular a distância ponto-a-ponto de cada elemento do vetor de características, culminando em um custo diretamente proporcional ao tamanho do vetor. Isso fica claro ao observar que o tempo de classificação do DTW com o SURF é muito mais elevado que as outra técnicas, devido ao fato de que o SURF gera vetores de características maiores que as outras técnicas utilizadas. Os tempos de treino da Elman RNN são os mais elevados devido à própria natureza do treinamento de uma rede neural recorrente, que precisa executar várias iterações até que o erro da rede diminua à um valor aceitável.

4.3.3 Experimento 3: Previsão de gestos dinâmicos

Os resultados coletados para cada novo *frame* adicionado no vetor de características são apresentados, assim torna-se possível observar a evolução da taxa de predição e do tempo necessário para classificação de cada novo *frame* adicionado. A Tabela 4.25 exibe os resultados obtidos utilizando a técnica CLCS no módulo de extração, adicionando os *frames* de 1 a 4 no vetor de características. Nesse resultado, o HMM demonstra uma evolução contínua na previsão, chegando à $54,4\%$ de gestos previstos corretamente, diferente do DTW, que não é capaz de prever o gesto com tão poucos *frames*, prevendo os gestos aleatoriamente.

A Tabela 4.26 exibe os resultados da aplicação do CLCS com a adição dos *frames* 5 à 8 no vetor de características. A taxa de previsão com o HMM continua em um aumento crescente, passando de $66,0\%$ de gestos previstos corretamente com 5 *frames*, para $75,98\%$ de gestos previstos corretamente com 8 *frames*. A partir da adição do sexto *frame*, o DTW começa a apresentar resultados melhores na previsão, em uma taxa de crescimento maior do que a do HMM, chegando à $35,20\%$ dos gestos previstos corretamente. Nota-se também um aumento expo-

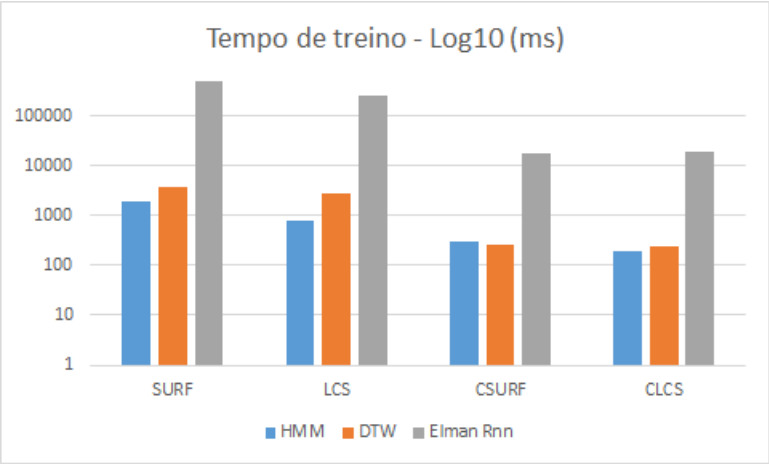

(a) Gráfico exibindo o tempo de treinamento de todas as combinações de técnicas, exibidos em escala logarítmica na base 10.

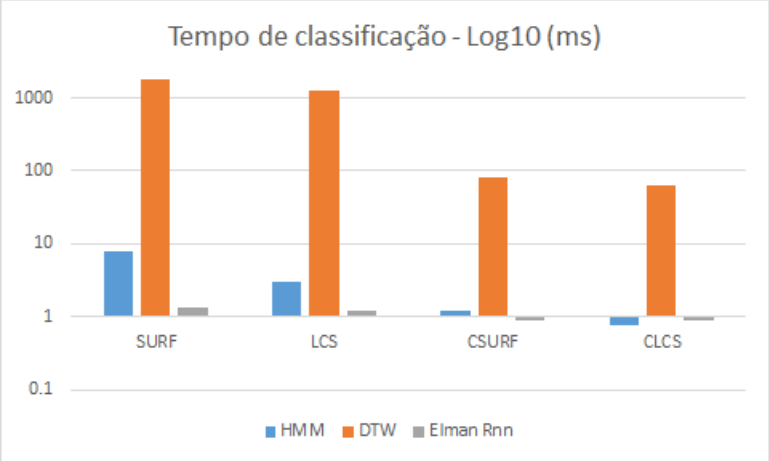

(b) Gráfico exibindo o tempo de classificação de um padrão para todas as combinações de técnicas, exibidos em escala logarítmica na base 10.

Figura 4.4: Gráficos exibindo os tempos de treinamento e classificação par todas as combinações de técnicas.

Tabela 4.26: Resultado da previsão adicionando-se os *frames* cinco à oito no vetor de características para o CLCS.

Técnica Classificação	Resultado	F5	F6	F7	F8
HMM	Taxa predição(%)	66,0	68,38	73,12	75,98
HMM	Desvio padrão	5,5	4,8	6,0	4,7
HMM	Tempo de predição(ms)	0,42	0,50	0,59	0,67
DTW	Taxa predição(%)	17,29	19,16	23,43	35,20
DTW	Desvio padrão	0,3	2,0	3,4	4,5
DTW	Tempo de predição(ms)	48,3	59,0	68,8	80,6

Tabela 4.27: Resultado da previsão adicionando-se os *frames* nove à doze no vetor de características para o CLCS.

Técnica Classificação	Resultado	F9	F10	F11	F12
HMM	Taxa predição(%)	76,7	80,0	82,2	81,7
HMM	Desvio padrão	5,2	4,6	6,0	5,8
HMM	Tempo de predição(ms)	0,76	0,83	0,92	1,00
DTW	Taxa predição(ms)(%)	49,58	64,06	76,77	94,84
DTW	Desvio padrão	4,9	5,3	6,8	4,0
DTW	Tempo de predição(ms)	90,23	98,06	104,87	80,6

Tabela 4.28: Resultado da previsão adicionando-se os *frames* treze e catorze no vetor de características para o CLCS.

Técnica Classificação	Resultado	F13	F14
HMM	Taxa predição(%)	80,15	80,72
HMM	Desvio padrão	5,9	5,4
HMM	Tempo de predição(ms)	1,09	1,18
DTW	Taxa predição(%)	96,76	97,00
DTW	Desvio padrão	1,14	1,11
DTW	Tempo de predição(ms)	115,34	123,04

nencial do tempo de predição gasto pelo DTW, o que não ocorre com o HMM, onde o aumento do tempo de previsão segue aumentando suavemente.

Os resultados obtidos com a adição dos *frames* nove à doze no vetor de características utilizado como entrada no módulo com CLCS, exibidos na Tabela 4.27, exibem uma estabilização na taxa de previsão obtida para o HMM, chegando a um patamar próximo aos $80,00\%$ de reconhecimento. Essa taxa é obtida já com a adição do décimo *frame*. O DTW continua apresentando uma taxa de crescimento no previsão exponencial, partindo de $49,58\%$ com à adição do *frame* nove e chegando até $94,84\%$ com à adição do *frames* doze.

A adição dos últimos dois *frames*, ao vetor de características do módulo de extração utilizando o CLCS, exibidos na Tabela 4.28, confirmam a estabilização do HMM na previsao dos gestos. A taxa de previsão continua a mesma, próximo a 80% de gestos reconhecidos corretamente, mesmo com a adição de todos os *frames*. O DTW também atinge uma estabilização, elevando um pouco a taxa de reconhecimento para $97,00$ % com todos os frames.

Aplicando a técnica de extração CSURF no módulo de extração, os resultados coletados foram similares aos obtidos com a aplicação do CLCS. Adicionando os quatro primeiros *frames* ao vetor de características, o HMM apresenta a mesma evolução gradual, iniciando de $35,57\%$ de gestos previstos corretamente, até $55,52\%$ já com quatro *frames*. O DTW apresenta pouca evolução e resultados muito baixos, chegando a obter $20,31\%$ dos gestos reconhecidos corretamente com quatro *frames*. A Tabela 4.29 exibe esse resultado.

A previsão adicionando os *frame* 5 à 8 no vetor de características, obtidas com

Tabela 4.29: Resultado da previsão adicionando-se os quatro primeiro *frames* no vetor de características para o CSURF.

Técnica Classificação	Resultado	F1	F2	F3	F4
HMM	Taxa predição(%)	35,57	41,87	50,15	55,52
HMM	Desvio padrão	4,6	4,4	5,9	5,9
HMM	Tempo de predição(ms)	0,09	0,18	0,26	0,35
DTW	Taxa predição(ms)(%)	16,53	17,18	17,18	20,31
DTW	Desvio padrão	0,0	0,0	0,0	6,98
DTW	Tempo de predição(ms)	11,37	46,22	68,65	91,26

Tabela 4.30: Resultado da previsão adicionando-se os *frames* cinco à oito no vetor de características para o CSURF.

Técnica Classificação	Resultado	F5	F6	F7	F8
HMM	Taxa predição(%)	62,91	67,65	72,23	73,69
HMM	Desvio padrão	5,56	5,64	4,60	5,64
HMM	Tempo de predição(ms)	0.44	0.51	0.61	0.69
DTW	Taxa predição(%)	18,43	24,37	39,37	63,12
DTW	Desvio padrão	1,3	2,8	4,7	7,8
DTW	Tempo de predição(ms)	113,52	135,41	157,05	180.65

o CSURF, apresenta um crescimento constante da taxa de previsão correta com o HMM. Já com o DTW, a previsão correta começa a subir rapidamente, a cada novo *frame* adicionado. Ao adicionar o *frame* 8, a taxa de reconhecimento para o DTW é de $63,12\%$ e a do HMM $73,69\%$. Como acontece com o CLCS, a taxa de crescimento do tempo gasto para a classificação no DTW também sobe rapidamente, diferente do que ocorre com o DTW. A Tabela 4.30 exibe esse resultado.

Ao adicionar os *frames* 9 à 12 no vetor de características, utilizando o CSURF como técnica de extração no módulo de extração, o HMM começa a estabilizar em um resultado, chegando à $77,76\%$ de previsões corretas no decimo segundo *frame*. Já o DTW continua aumentando sua taxa de reconhecimento, partindo de $80,31\%$ no *frame* número nove, e chegando até $92,81\%$ no décimo segundo *frame*. A Tabela 4.31 exibe esse resultado.

Tabela 4.31: Resultado da previsão adicionando-se os *frames* nove à doze no vetor de características para o CSURF.

Técnica Classificação	Resultado	F9	F10	F11	F12
HMM	Taxa predição(%)	72,13	75,41	74,84	77,76
HMM	Desvio padrão	5,64	4,6	5,6	5,7
HMM	Tempo de predição(ms)	0,78	0,86	0,95	1.04
DTW	Taxa predição(ms)(%)	80,31	85,31	88,12	92,81
DTW	Desvio padrão	5,6	2,3	4,0	5,4
DTW	Tempo de predição(ms)	202,29	225,76	262,84	267,46

Tabela 4.32: Resultado da previsão adicionando-se os *frames* treze e catorze no vetor de características para o CLCS.

Técnica Classificação	Resultado	F13	F14
HMM	Taxa predição(%)	76,25	77,44
HMM	Desvio padrão	5.3	4,8
HMM	Tempo de predição(ms)	1.13	1.23
DTW	Taxa predição(%)	93.12	94.08
DTW	Desvio padrão	1.3	2.0
DTW	Tempo de predição(ms)	289.87	312.66

Tabela 4.33: Resultado da previsão adicionando-se os quatro primeiro *frames* no vetor de características para o LCS.

Técnica Classificação	Resultado	F1	F2	F3	F4
HMM	Taxa predição(%)	36,14	35,20	34,53	40,46
HMM	Desvio padrão	6,67	6,49	4,79	6,45
HMM	Tempo de predição(ms)	0,27	0,48	0,72	0.94
DTW	Taxa predição(ms)(%)	12,50	14,37	13,75	14,37
DTW	Desvio padrão	2,47	5,11	4,33	1,71
DTW	Tempo de predição(ms)	89,39	179,87	294,65	356,69

A estabilização do HMM, assim como ocorre com a utilização do CLCS, é confirmada para o CSURF ao adicionar-se os dois últimos *frames* ao vetor de características. A Tabela 2.32 exibe o resultado. O DTW continua crescendo, dessa vez menos, atingindo $94,08\%$ de previsão, com todos os *frames*.

Os últimos resultados obtidos foram com a utilização do LCS no módulo de extração. A Tabela 4.33 exibe os dados adicionando-se os quatro primeiros *frames*. Observa-se que, assim como o CLCS e o CSURF, o HMM apresenta uma evolução constante na taxa de previsão, começando de $36,14\%$ e atingindo $40,46\%$ no quarto *frame*. O DTW não apresenta evolução no início.

Os resultados obtidos ao se adicionar os *frames* cinco à 8 no vetor de características extraído pelo LCS mostram um avanço do HMM, mas diferente dos resultados obtidos pelo CLCS e CSURF, a taxa com o LCS se mostra mais baixa, chegando à $52,23\%$ de previões reconhecidas corretamente no oitavo *frame*. A partir do *frame* quatro, a taxa de reconhecimento do DTW passa a subir, chegando à $65,00\%$ no frame 8, já ultrapassando o resultado obtido pelo HMM. Pode ser observado também um alto tempo na previsão do gesto com o DTW, muito mais alto do que em qualquer outro resultado, chegando a $700ms$ no oitavo *frame*. A Tabela 4.34 ilustra esse resultado.

Adicionando os *frames* nove à doze no vetor de características extraído pelo LCS, percebe-se a estagnação no resultado da previsão de gestos corretos obtidos pelo HMM, chegando a $54,42\%$ de previsões corretas no *frame* 12. Já o DTW avança à passos largos, e obtém uma taxa de $82,50\%$ no frame 12, porém o tempo de classificação chega a $1060,92$ também no *frame* 12. A Tabela 4.35 exibe esse

Tabela 4.34: Resultado da previsão adicionando-se os *frames* cinco à oito no vetor de características para o LCS.

Técnica Classificação	Resultado	F5	F6	F7	F8
HMM	Taxa predição(%)	44,27	48,80	49,47	52,23
HMM	Desvio padrão	6,54	5,97	7,03	6,02
HMM	Tempo de predição(ms)	1,16	1,38	1,60	1.83
DTW	Taxa predição(ms)(%)	21,87	32,18	47,50	65,00
DTW	Desvio padrão	2,20	4,22	8,0	3,92
DTW	Tempo de predição(ms)	444,30	529,94	624,53	700,98

Tabela 4.35: Resultado da previsão adicionando-se os *frames* nove à doze no vetor de características para o LCS.

Técnica Classificação	Resultado	F9	F10	F11	F12
HMM	Taxa predição(%)	53,43	52,65	53,34	54,42
HMM	Desvio padrão	5,98	7,68	5,37	6,11
HMM	Tempo de predição(ms)	2,06	2,25	2,46	2.70
DTW	Taxa predição(ms)(%)	75,93	78,43	80,31	82,50
DTW	Desvio padrão	7,46	3,00	6,11	4,73
DTW	Tempo de predição(ms)	785,25	876,76	962,54	1060,92

resultado.

Ao adicionar os dois últimos *frames* ao vetor de características extraido pelo LCS, observa-se a estabilização do resultado em ambas as técnicas, o DTW atingindo $89,06\%$ e o HMM $52,55\%$. A Tabela 4.36 detalha esse resultado.

Os resultados obtidos mostram que as técnicas de extração de características testadas atingiram diferentes resultados. Observando somente a taxa de classificação, percebe-se que o HMM detém uma subida constante, porém suave. Ao obter metade dos *frames* de um gesto completo, o HMM já esta perto de estabilizar a taxa de reconhecimento. Já o DTW oferece melhores resultados após a inserção de metade dos *frames* no vetor de características. A Figura 4.5 ilustra essa tendência.

Observando o tempo de classificação de um padrão, percebe-se como a previsão de gestos é importante. A Figura 4.6 exibe a evolução do tempo de predição para

Tabela 4.36: Resultado da previsão adicionando-se os *frames* treze e catorze no vetor de características para o LCS.

Técnica Classificação	Resultado	F13	F14
HMM	Taxa predição(%)	53,59	52,55
HMM	Desvio padrão	6.0	5,7
HMM	Tempo de predição(ms)	2,70	2,91
DTW	Taxa predição(%)	89,68	89,06
DTW	Desvio padrão	4,6	1,1
DTW	Tempo de predição(ms)	1131.02	1237.47

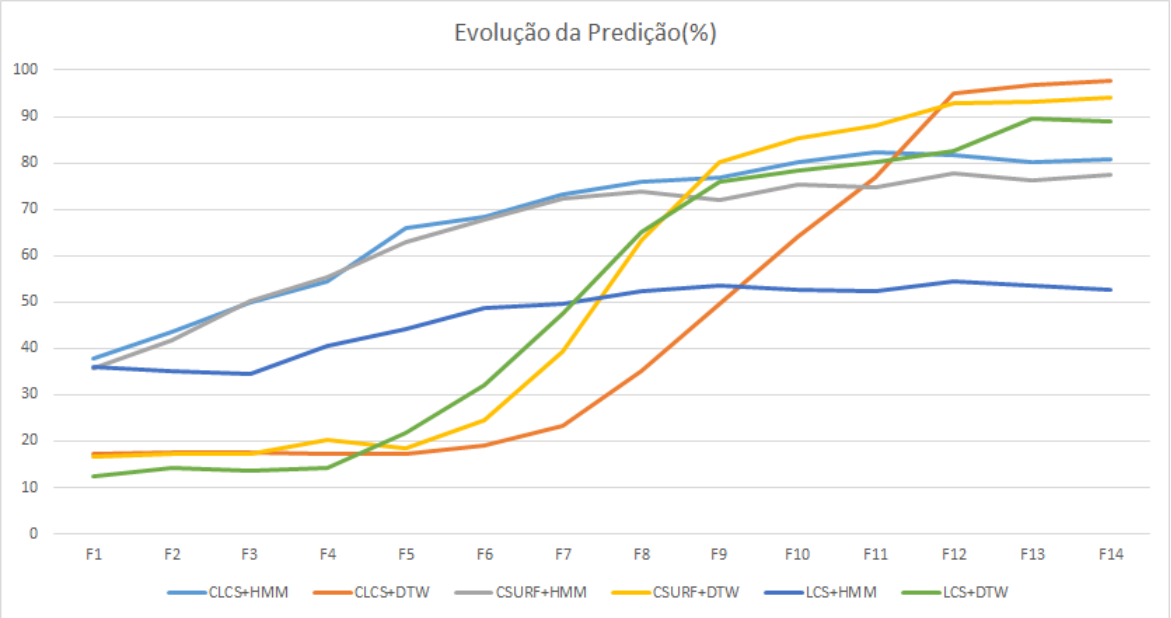

Figura 4.5: Gráfico exibindo a evolução da predição de gestos corretos para todas as combinações testadas.

todas as combinações. Percebe-se que o HMM possui um tempo de classificação baixo. Ao chegar à metade dos *frames* inseridos no vetor de características, o HMM já obtém uma taxa de previsão estabilizada, que permanece muito similar à taxa encontrada com todos os *frames* , porém possui um tempo de execução muito menor. Ao tempo que se reconhece um gesto completo, pode-se prever dois gestos. O mesmo fenômeno pode ser observado no DTW, ainda de forma mais drástica, já que o número de características no vetor de características influencia diretamente no tempo de processamento do DTW.

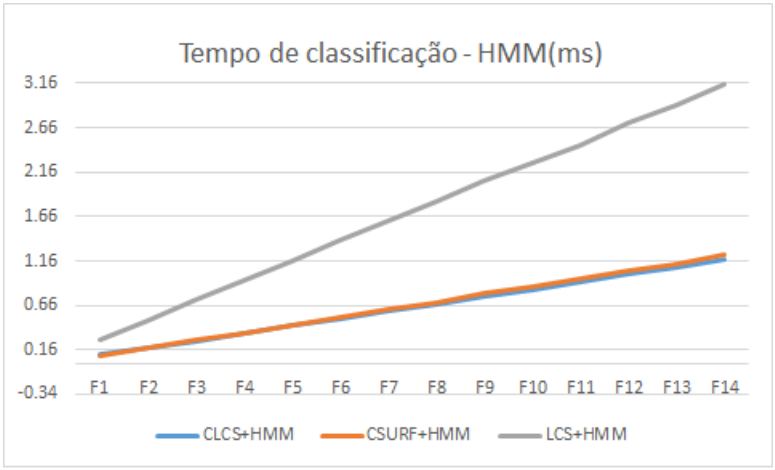

(a) Gráfico exibindo a evolução do tempo de classificação para previsão de gestos utilizando o HMM.

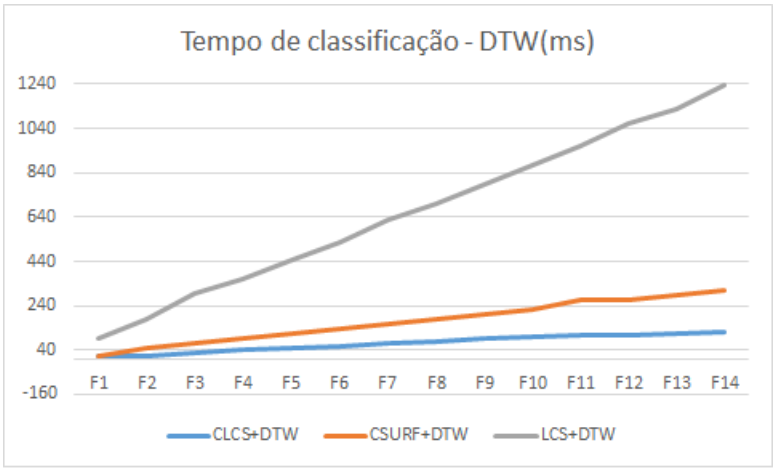

(b) Gráfico exibindo a evolução do tempo de classificação para previsão de gestos utilizando o DTW.

Figura 4.6: Gráficos de comparação do tempo de treinamento e classificação par todas as combinações de técnicas.

Capítulo 5

Conclusão e Trabalhos Futuros

5.1 Contribuições

Durante o desenvolvimento deste trabalho de dissertação, alguns artigos e resumos foram publicados utilizando os resultados obtidos. Seguem os trabalhos publicados:

Evento: 28th Symposium On Applied Computing *Título*: Convexity Local Contour Sequences for Gesture Recognition *Resumo*: Algorithms for hand feature extraction used in gesture recognition systems have some problems such as unnecessary information gathering. This paper proposes a novel method for feature extraction in gesture recognition systems based on the Local Contour Sequence (LCS). It is called the Convexity Local Contour Sequence (CLCS) and represents the hand shape only with the significant information. This generates a smaller output result, but capable to model an entire dynamic gesture. It is used to classify dynamic gestures with an Elman Recurrent Network and Hidden Markov model and presents a better result compared to regular LCS.

Evento: 23rd International Conference on Artificial Neural Networks *Título*: An Effective Dynamic Gesture Recognition System based on the Feature Vector Reduction for SURF and LCS *Resumo*: Speed Up Robust Feature (SURF) and Local Contour Sequence(LCS) are methods used for feature extraction techniques for dynamic gesture recognition. A problem presented by these techniques is the large amount of data in the outputvector which dificult the classification task. This paper presents a novel method for dimensionality reduction of the features extracted by SURF and LCS, called Convexity Approach. The proposed method is evaluated in a gesture recognition task and improves the recognition rate of LCS while SURF while decreases the amount of data in the output vector.

Evento: French-Brazilian Workshop on Numerical and Symbolic Methods of Data Analysis 2013 *Título*: Using a Dynamic Time Wrapper to Recognize Dynamic Gestures *Resumo*: gesture recognition systems provide a natural, userfriendly way of interaction with the computer which is more familiar to the human beings. Gesture recognition has a wide area of application including human machine interaction, sign language and video game technology. The proposed system uses the Convexity Local Contour Sequence(CLCS) to extract the features in a dy-

namic gesture dataset. This technique uses a distance calculation based on the hand shape to extract a feature vector of each frame. It is speed and hand size invariant, so it can be used for gesture recognition of different users. A Dynamic Time Wrapper (DTW) is used in the classification task of the proposed system. The DTW compares two distinct sequences, with diferent sizes. The compared distance is used to classify a gesture based on the previously learned sequences.

Além dos trabalhos citados acima uma publicação para o *Journal Expert Systems With Applications*, da *Elsevier*, está sendo compilada. Uma evolução deste trabalho será executada como forma do projeto de PHD intitulado *"Using Computer Vision to provide Real-Time Sign Language Interaction with a Robot."* a ser realizado no laboratório *Knowledge Technoly Group*, na Universidade de Hamburgo - Alemanha.

5.2 Conclusão

Esse trabalho de dissertação descreve a proposta, implementação e testes de um sistema para reconhecimento e previsão de gestos dinâmicos realizados com a mão de um usuário. A área de reconhecimento de gestos dinâmicos, embora muito abordada por diversos trabalhos na última década, vem esbarrando em alguns problemas, como o processamento de imagens em um tempo hábil para ser utilizada em tempo real e uma base de gestos em que se possa realizar diversos *benchmarks*.

Para resolver o problema citado, uma técnica de extração de características é proposta e analisada. Essa técnica, denominada Abordagem Convexa, seleciona pontos no contorno da mão que podem representar todo o contorno. A escolha desses pontos se dá dinamicamente, sendo selecionados os pontos que melhor descrevem a forma da mão na imagem.

Ao se utilizar a Abordagem Convexa nos contornos obtidos pelas técnicas de extração *Local Contour Sequence* (LCS) e *Speed Up Robust Feature*(SURF), o vetor de característica extraído se mostra menor, o que reflete em uma boa taxa de reconhecimento, além de diminuir o tempo necessário para reconhecer gestos corretamente.

O sistema proposto possui dois módulos, um para extração de características e um para a classificação do gesto. De forma a realizar testes de validação no sistema foram implementadas quatro técnicas no módulo de extração e três no módulo de classificação. Para extração foram implementadas as técnicas LCS e SURF, bem como a aplicação da Abordagem Convexa nos contornos de mão extraídos por essas duas técnicas, gerando o CLCS e o CSURF respectivamente.

Devido a necessidade de uma base de dados que suportasse os experimentos, uma base de gestos dinâmicos foi desenvolvida, denominada Base de Gestos Dinâmicos RPPDI, e distribuída gratuitamente pela internet. Essa nova base de gestos dinâmicos contém sete gestos, com vários exemplos para cada gesto. Os gestos são realizados pela mão de um usuário sob um fundo escuro e são compostos por 14 imagens, representando uma evolução no tempo da postura da mão.

Foram realizados três experimentos, o primeiro denominado Reconhecimento

de gestos estáticos, o segundo Reconhecimento de gestos dinâmicos e o terceiro Previsão de gestos dinâmicos. No primeiro experimento, algumas poses de mão da base de gestos foram selecionadas, de forma a simular gestos estáticos. As quatro técnicas de extração forma utilizadas em dois classificadores: uma Rede Neural MLP e um *Dynamic Time Warping* (DTW). No segundo experimento, os sete gestos completos da base de gestos são utilizados. No módulo de extração são utilizada as quatro técnicas de extração citadas anteriormente. No módulo de extração são utilizadas as técnicas DTW, Modelo Oculto de Markov (HMM) e Rede Neural Recorrente de Elman (Elman RNN). No terceiro experimento, os sete gestos da base de gesto dinâmicos são utilizados. O sistema utiliza como entada gestos incompletos, somente alguns *frames* cada gesto. Vários testes são realizados, cada um contendo uma certa quantidade de *frames*, de forma a avaliar a capacidade de predição de gestos para cada combinação de técnica. No módulo de classificação, o terceiro experimento utiliza um DTW e um Modelo Oculto de Markov.

Os resultados obtidos demonstram que o CLCS e o CSURF, técnicas derivadas do LCS e SURF utilizando a Abordagem Convexa, se mostraram superiores em taxas de classificação e tempo de processamento do que as técnicas cujo são originárias. Esse fator se deve ao tamanho e aos elementos do vetor de característica extraído pela Abordagem Convexa. Como os pontos selecionados para a extração conseguem representar melhor a postura da mão, as taxas de classificação em todos os classificadores testados foram mais elevados. Dentre os classificadores o DTW é aquele que apresenta a melhor taxa de reconhecimento, tendo como desvantagem um maior tempo necessário para a classificação dos padrões. O HMM foi a técnica que conseguiu os melhores tempos para a classificação.

Os resultados obtidos no terceiro experimento, previsão, demonstram que o uso da Abordagem Convexa pode ser utilizada para o reconhecimento de padrões incompletos em conjunto com o DTW e o HMM. Os valores obtidos deixam claro que a previsão de gestos pode ser utilizada para agilizar no trabalho de reconhecimento, já que com metade dos *frames* capturados a quantidade de gestos reconhecidos corretamente tende a estabilizar, quando se usa o HMM, enquanto o tempo para a classificação é metade do que o necessário para classificar um gesto completo.

5.3 Trabalhos Futuros

Esse trabalho pode ser estendido em várias linhas de pesquisa, como por exemplo:

- Expandir a base de gestos proposta, capturando mais gestos;
- Criar uma base de sinais de LIBRAS, a Língua Brasileira de Sinais;
- Implementar métodos de extração de contorno de mão em fundos complexos;
- Implementar uma abordagem mista, utilizando a previsão de gestos de forma à auxiliar o reconhecimento;

- Realizar testes com gestos obtidos em tempo real;
- Incrementar os tipos de características extraídas, além do contorno, como características biométricas.
- Implementar as técnicas em um robô humanoide para fins de comunicação homem-robô.

Referências Bibliográficas

[AAC+91] S. Amato, B. Apolloni, G. Caporali, U. Madesani, and A. Zanaboni. Simulated annealing approach in backpropagation. *Neurocomputing*, 3(5–6):207 – 220, 1991.

[AC99] J. K. Aggarwal and Q. Cai. Human motion analysis: a review. *Comput. Vis. Image Underst.*, 73(3):428–440, March 1999.

[AL06] M. Ahmad and Seong-Whan Lee. Hmm-based human action recognition using multiview image sequences. In *Pattern Recognition, 2006. ICPR 2006. 18th International Conference on*, volume 1, pages 263–266, 2006.

[ATK11] Y.F.G. Abdul, F.W.H. Tze, and K.T.T. Kin. Feature extraction from 2d gesture trajectory in malaysian sign language recognition. In *Mechatronics (ICOM), 2011 4th International Conference On*, pages 1 –6, may 2011.

[BAESS11] S. Bilal, R. Akmeliawati, M.J. El Salami, and A.A. Shafie. Vision-based hand posture detection and recognition for sign language x2014; a study. In *Mechatronics (ICOM), 2011 4th International Conference On*, pages 1–6, 2011.

[BDH13] S. Bodiroza, G. Doisy, and V.V. Hafner. Position-invariant, real-time gesture recognition based on dynamic time warping. In *Human-Robot Interaction (HRI), 2013 8th ACM/IEEE International Conference on*, pages 87–88, 2013.

[BETVG08] Herbert Bay, Andreas Ess, Tinne Tuytelaars, and Luc Van Gool. Speeded-up robust features (surf). *Comput. Vis. Image Underst.*, 110(3):346–359, June 2008.

[BJB+13] Pablo V. A. Barros, Nestor T. M. Junior, Juvenal M. M. Bisneto, Bruno J. T. Fernandes, Byron L. D. Bezerra, and Sergio M. M. Fernandes. Convexity local contour sequences for gesture recognition. In *Proceedings of the 28th Annual ACM Symposium on Applied Computing*, SAC '13, pages 34–39, New York, NY, USA, 2013. ACM.

[BNT09] J. Bernardes, R. Nakamura, and R. Tori. Design and implementation of a flexible hand gesture command interface for games based on computer vision. In *Games and Digital Entertainment (SBGAMES), 2009 VIII Brazilian Symposium on*, pages 64–73, 2009.

[CH11] F.M. Ciaramello and S.S. Hemami. A computational intelligibility model for assessment and compression of american sign language video. *Image Processing, IEEE Transactions on*, 20(11):3014–3027, 2011.

[COB+04] Sung-Jung Cho, Jong-Koo Oh, Won-Chul Bang, Wook Chang, Eunseok Choi, Yang Jing, Joonkee Cho, and Dong-Yoon Kim. Magic wand: a hand-drawn gesture input device in 3-d space with inertial sensors. In *Frontiers in Handwriting Recognition, 2004. IWFHR-9 2004. Ninth International Workshop on*, pages 106–111, 2004.

[CR11] D. Chivers and P. Rodgers. Gesture-based input for drawing schematics on a mobile device. In *Information Visualisation (IV), 2011 15th International Conference on*, pages 127–134, 2011.

[DdM10] Evgueni Dodonov and Rodrigo Fernandes de Mello. A novel approach for distributed application scheduling based on prediction of communication events. *Future Gener. Comput. Syst.*, 26(5):740–752, May 2010.

[DP73] David H. Douglas and Thomas K. Peucker. Algorithms for the reduction of the number of points required to represent a digitized line or its caricature. *Cartographica: The International Journal for Geographic Information and Geovisualization*, 10(2):112–122, October 1973.

[For73] Jr. Forney, G.D. The viterbi algorithm. *Proceedings of the IEEE*, 61(3):268–278, 1973.

[FWCL07] Yikai Fang, Kongqiao Wang, Jian Cheng, and Hanqing Lu. A real-time hand gesture recognition method. In *Multimedia and Expo, 2007 IEEE International Conference on*, pages 995–998, 2007.

[Gav99] D. M. Gavrila. The visual analysis of human movement: A survey. *Computer Vision and Image Understanding*, 73:82–98, 1999.

[GM01] L. Gupta and Suwei Ma. Gesture-based interaction and communication: automated classification of hand gesture contours. *Systems, Man, and Cybernetics, Part C: Applications and Reviews, IEEE Transactions on*, 31(1):114 –120, feb 2001.

[Han10] Youngmo Han. A low-cost visual motion data glove as an input device to interpret human hand gestures. *Consumer Electronics, IEEE Transactions on*, 56(2):501–509, 2010.

[Hay99] Simon Haykin. *Neural networks : a comprehensive foundation*. Prentice Hall, Upper Saddle River (N.J.), 1999. La page de couv. porte en plus : International edition.

[HJAJG09] A.J. Husssain, A.J. Jameel, D. Al-Jumeily, and R. Ghazali. Speech prediction using higher order neural networks. In *Innovations in Information Technology, 2009. IIT '09. International Conference on*, pages 294–298, 2009.

[HK12] Haitham Sabah Hasan and S.Abdul Kareem. Human computer interaction for vision based hand gesture recognition: A survey. In *Advanced Computer Science Applications and Technologies (ACSAT), 2012 International Conference on*, pages 55–60, 2012.

[HMWA11] Yu Huang, Dorothy Monekosso, Hui Wang, and J.C. Augusto. A concept grounding approach for glove-based gesture recognition. In *Intelligent Environments (IE), 2011 7th International Conference on*, pages 358–361, 2011.

[HN07] E.E. Helander and J. Nurminen. A novel method for prosody prediction in voice conversion. In *Acoustics, Speech and Signal Processing, 2007. ICASSP 2007. IEEE International Conference on*, volume 4, pages IV–509–IV–512, 2007.

[IK12] Noor Adnan Ibraheem and Rafiqul Zaman Khan. Article: Survey on various gesture recognition technologies and techniques. *International Journal of Computer Applications*, 50(7):38–44, July 2012. Published by Foundation of Computer Science, New York, USA.

[Jai01] L. Jain. *Recurrent Neural Networks*. CRC Press, 1st edition, 2001.

[JJS+12a] Soonmook Jeong, Jungdong Jin, Taehoun Song, Keyho Kwon, and Jae Wook Jeon. Single-camera dedicated television control system using gesture drawing. *Consumer Electronics, IEEE Transactions on*, 58(4):1129–1137, 2012.

[JJS+12b] Soonmook Jeong, Jungdong Jin, Taehoun Song, Keyho Kwon, and Jae Wook Jeon. Single-camera dedicated television control system using gesture drawing. *Consumer Electronics, IEEE Transactions on*, 58(4):1129–1137, 2012.

[JLK11] Eunseok Jeong, Jaehong Lee, and DaeEun Kim. Finger-gesture recognition glove using velostat (iccas 2011). In *Control, Automation and Systems (ICCAS), 2011 11th International Conference on*, pages 206–210, 2011.

[JSFJ11] Xinghao Jiang, Tanfeng Sun, Bing Feng, and Chengming Jiang. A space-time surf descriptor and its application to action recognition with video words. In *Fuzzy Systems and Knowledge Discovery (FSKD), 2011 Eighth International Conference on*, volume 3, pages 1911 –1915, july 2011.

[KE11] N. Kouiroukidis and G. Evangelidis. The effects of dimensionality curse in high dimensional knn search. In *Informatics (PCI), 2011 15th Panhellenic Conference on*, pages 41–45, 2011.

[KGV83] S. Kirkpatrick, C. D. Gelatt, and M. P. Vecchi. Optimization by simulated annealing. *Science*, 220:671–680, 1983.

[KK10] S. Koceski and N. Koceska. Vision-based gesture recognition for human-computer interaction and mobile robot's freight ramp control. In *Information Technology Interfaces (ITI), 2010 32nd International Conference on*, pages 289–294, 2010.

[KTK09] Ji-Hwan Kim, Nguyen Duc Thang, and Tae-Seong Kim. 3-d hand motion tracking and gesture recognition using a data glove. In *Industrial Electronics, 2009. ISIE 2009. IEEE International Symposium on*, pages 1013–1018, 2009.

[LBM01] C. Leubner, C. Brockmann, and H. Muller. Computer-vision-based human-computer interaction with a back projection wall using arm gestures. In *Euromicro Conference, 2001. Proceedings. 27th*, pages 308–314, 2001.

[LEBW70] G. Souled L. E. Baum, T. Peterie and N. Weiss. A maximization technique occurring in the statistical analysis of probabilistic functions of markov chains. pages 164–171, 1970.

[Lee06] Seong-Whan Lee. Automatic gesture recognition for intelligent human-robot interaction. In *Automatic Face and Gesture Recognition, 2006. FGR 2006. 7th International Conference on*, pages 645–650, 2006.

[LH10] Doe-Hyung Lee and Kwang-Seok Hong. Game interface using hand gesture recognition. In *Computer Sciences and Convergence Information Technology (ICCIT), 2010 5th International Conference on*, pages 1092–1097, 2010.

[Lin98] Tony Lindeberg. Feature detection with automatic scale selection. *Int. J. Comput. Vision*, 30(2):79–116, November 1998.

[LNV+12] M.A.S. Lima, P.F.R. Neto, R.R. Vidal, G.H.E.L. Lima, and J.F. Santos. Libras translator via web for mobile devices. In *Telematics and Information Systems (EATIS), 2012 6th Euro American Conference on*, pages 1–4, 2012.

[Low04] David G. Lowe. Distinctive image features from scale-invariant keypoints. *Int. J. Comput. Vision*, 60(2):91–110, November 2004.

[MAZ08] M. Maraqa and R. Abu-Zaiter. Recognition of arabic sign language (arsl) using recurrent neural networks. In *Applications of Digital Information and Web Technologies, 2008. ICADIWT 2008. First International Conference on the*, pages 478 –481, aug. 2008.

[Mee11] S. Meena. A study on hand gesture recognition technique. Master's thesis, National Institute Of Technology, Rourkela,India, 2011.

[Mel87] Avraham A. Melkman. On-line construction of the convex hull of a simple polyline. *Inf. Process. Lett.*, 25(1):11–12, April 1987.

[MT91] Kouichi Murakami and Hitomi Taguchi. Gesture recognition using recurrent neural networks. In *Proceedings of the SIGCHI conference on Human factors in computing systems: Reaching through technology*, CHI '91, pages 237–242, New York, NY, USA, 1991. ACM.

[MUK+06] A. Mori, S. Uchida, R. Kurazume, R.-I. Taniguchi, T. Hasegawa, and H. Sakoe. Early recognition and prediction of gestures. In *Pattern Recognition, 2006. ICPR 2006. 18th International Conference on*, volume 3, pages 560–563, 2006.

[Ots79] N. Otsu. A threshold selection method from gray-level histograms. *Systems, Man and Cybernetics, IEEE Transactions on*, 9(1):62 –66, jan. 1979.

[PSH97] V.I. Pavlovic, R. Sharma, and T.S. Huang. Visual interpretation of hand gestures for human-computer interaction: a review. *Pattern Analysis and Machine Intelligence, IEEE Transactions on*, 19(7):677–695, 1997.

[RA11] S.S. Rautaray and A. Agrawal. Interaction with virtual game through hand gesture recognition. In *Multimedia, Signal Processing and Communication Technologies (IMPACT), 2011 International Conference on*, pages 244–247, 2011.

[Rab90] Lawrence R. Rabiner. Readings in speech recognition. chapter A tutorial on hidden Markov models and selected applications in speech recognition, pages 267–296. Morgan Kaufmann Publishers Inc., San Francisco, CA, USA, 1990.

[RMM+09] J. Ravikiran, Kavi Mahesh, Suhas Mahishi, R. Dheeraj, S. Sudheender, and Nitin V. Pujari. Finger detection for sign language recognition. In *Proc. International Conference on Computer Science, International Multi-Conference of Engineers and Computer Scientists &Ondash; IMECS 2009*. ICCS-2009, IAENG, Hong Kong, 2009.

[Ros]

[SA07] T. Shanableh and K. Assaleh. Two tier feature extractions for recognition of isolated arabic sign language using fisher's linear discriminants. In *Acoustics, Speech and Signal Processing, 2007. ICASSP 2007. IEEE International Conference on*, volume 2, pages II–501–II–504, 2007.

[SCH+05] M. Sen, I. Corretjer, F. Haim, S. Saha, S.S. Bhattacharyya, J. Schlessman, and W. Wolf. Computer vision on fpgas: Design methodology and its application to gesture recognition. In *Computer Vision and Pattern Recognition - Workshops, 2005. CVPR Workshops. IEEE Computer Society Conference on*, pages 133–133, 2005.

[SCO11] J. Schlecht, B. Carque, and B. Ommer. Detecting gestures in medieval images. In *Image Processing (ICIP), 2011 18th IEEE International Conference on*, pages 1285–1288, 2011.

[SGS11] K.V. Satya, A.K. Gogoi, and G. Sahu. Regressive linear prediction with doublet for speech signals. In *Control System, Computing and Engineering (ICCSCE), 2011 IEEE International Conference on*, pages 33–36, 2011.

[SHL+98] Mu-Chun Su, Hi Huang, Chia-Hsien Lin, Chen-Lee Huang, and Chi-Da Lin. Application of neural networks in spatio-temporal hand gesture recognition. In *Neural Networks Proceedings, 1998. IEEE World Congress on Computational Intelligence. The 1998 IEEE International Joint Conference on*, volume 3, pages 2116–2121 vol.3, 1998.

[Skl82] Jack Sklansky. Finding the convex hull of a simple polygon. *Pattern Recogn. Lett.*, 1(2):79–83, December 1982.

[SP09] E. Stergiopoulou and N. Papamarkos. Hand gesture recognition using a neural network shape fitting technique. *Eng. Appl. Artif. Intell.*, 22(8):1141–1158, December 2009.

[ST07] D.G. Stavrakoudis and J.B. Theocharis. A recurrent fuzzy neural network for adaptive speech prediction. In *Systems, Man and Cybernetics, 2007. ISIC. IEEE International Conference on*, pages 2056–2061, 2007.

[VH99] E. Varoglu and K. Hacioglu. Speech prediction using recurrent neural networks. *Electronics Letters*, 35(16):1353–1355, 1999.

[VJ01] P. Viola and M. Jones. Rapid object detection using a boosted cascade of simple features. In *Computer Vision and Pattern Recognition, 2001. CVPR 2001. Proceedings of the 2001 IEEE Computer Society Conference on*, volume 1, pages I–511–I–518 vol.1, 2001.

[XGDT10] Wang Xinyu, Sun Guan, Han Dong, and Zhang Ting. Data glove gesture recognition based on an improved neural network. In *Control Conference (CCC), 2010 29th Chinese*, pages 2434–2437, 2010.

[YY12] Chang-Tsun Li Yi Yao. Hand posture recognition using surf with adaptive boosting. In *British Machine Vision Conference*, 2012.

[ZCZ+08] Yu Zhou, Xilin Chen, Debin Zhao, Hongxun Yao, and Wen Gao. Mahalanobis distance based polynomial segment model for chinese sign language recogniton. In *Multimedia and Expo, 2008 IEEE International Conference on*, pages 317–320, 2008.

[ZWD11] Hui Zhang, Yongqi Wang, and Chen Deng. Application of gesture recognition based on simulated annealing bp neural network. In *Electronic and Mechanical Engineering and Information Technology (EMEIT), 2011 International Conference on*, volume 1, pages 178 –181, aug. 2011.

[ZZ08] Guofeng Zhang and Dongming Zhang. Research on vision-based multi-user gesture recognition human-computer interaction. In *System Simulation and Scientific Computing, 2008. ICSC 2008. Asia Simulation Conference - 7th International Conference on*, pages 1455–1458, 2008.